

RODRIGO DEL ROSSO

ANÁLISIS DE SERIES TEMPORALES

Trabajo Práctico N° 1

FERNANDO COZ
TAMARA GASQUEZ
JOHANNA NOVAL
GERMAN SANTAMARIA

Resumen Ejecutivo



Este informe se enfoca en el análisis de datos de una oficina gubernamental para prever la demanda de atención ciudadana, optimizando la asignación de recursos. Se emplea la metodología de Box-Jenkins, destacando modelos ARIMA y VAR para cuatro series temporales de frecuencia diaria relativas a: mensajes de WhatsApp, atención presencial, trámites a distancia y planes de pagos.

En la fase inicial, los gráficos revelan cierta estacionariedad, con picos relacionados con eventos promocionales. Las pruebas de raíces unitarias indican que solo la serie de WhatsApp es estacionaria, llevando a la diferenciación de todas las series. El comando autoarima selecciona el mejor modelo, comparándolo con otros según métricas como MSE, MAE y RMSE.

El análisis de diagnóstico evalúa la calidad del ajuste y patrones no modelados en los residuos. Los mejores modelos se eligen según métricas de rendimiento, demostrando la eficacia de ARIMA y VAR en diferentes contextos. Para las series de consultas presenciales y para planes de pago los modelos ARIMA(1,0,1) resultaron mejores pronosticadores. Mientras que para las series de consultas por WhatsApp y Trámites a distancia los modelos VAR(4) obtuvieron mejores resultados.

Índice

Tabla de contenido

- 01** Introducción
Página 5

- 02** Marco Teórico
Página 7

- 03** Análisis de Resultados
Página 11

- 04** Conclusiones
Página 44

- 05** Referencias Bibliográficas
Página 46

- 06** Apéndices
Página 48

- 07** Repositorio del código
Página 50

Introducción

INTRODUCCIÓN

En el ámbito de la gestión de servicios públicos, la eficiencia y calidad en la atención ciudadana son aspectos cruciales para garantizar una administración efectiva y satisfactoria. Este informe se enfoca en el análisis de datos obtenidos de una oficina gubernamental de recaudación y servicios al contribuyente, con el objetivo principal de utilizar series temporales para predecir la demanda de atención a través de distintos canales de comunicación.

La investigación busca optimizar la asignación de recursos humanos para mejorar la calidad y eficiencia de los servicios prestados por la oficina pública. Una asignación más eficiente de recursos permite una atención oportuna y adecuada, reduciendo tiempos de espera y aumentando la satisfacción general. Además, se busca explorar posibles relaciones o correlaciones entre variables que representan diferentes canales de atención, como los mensajes de WhatsApp y los turnos presenciales solicitados.

La metodología desarrollada por Box-Jenkins (1970), para modelar y pronosticar series temporales es utilizada en una amplia gama de aplicaciones, principalmente en finanzas, ya que captura la complejidad de las series temporales mediante la combinación de componentes autorregresivos, de media móvil e integrados conocidos como modelos ARIMA (Autoregressive Integrated Moving Average). Posteriormente Sims (1980) desarrolló los modelos VAR (Vector Autoregressive) como una matriz que combina procesos autorregresivos de series estacionarias como elemento de pronóstico de series de tiempo.

Como se mencionó anteriormente se analizarán cuatro series temporales específicas que ofrecen una visión completa de la actividad de la oficina gubernamental de recaudación referidas a la cantidad de mensajes de WhatsApp recibidos (WAPP), las personas atendidas de manera presencial (TP), los trámites a distancia iniciados (TAD), y los planes de pagos confeccionados (PP). El período de análisis comprende datos diarios desde el 15 de marzo de 2022 hasta el 29 de septiembre de 2023. La información se registró únicamente para días hábiles, excluyendo fines de semana y días festivos. En casos excepcionales con datos faltantes por problemas técnicos, se aplicaron métodos para mantener la integridad y continuidad del análisis, como la sustitución de datos faltantes por la mediana de la serie.

Para alcanzar el objetivo de esta investigación, se seguirá la metodología de Box-Cox. En primer lugar, se graficarán las series originales con el propósito de evaluar su comportamiento a lo largo del tiempo y analizar si es necesario aplicar transformaciones en caso de que no sean estacionarias aplicando el análisis gráfico de las funciones de autocorrelación (FAC), de autocorrelación parcial (FACP) y de autocorrelación simple (FAS), proporcionando información valiosa sobre la estructura de dependencia temporal en los datos junto con diversas pruebas de raíces unitarias para determinar la estacionariedad de las series tales como los test de Dickey-Fuller, Phillips-Perron y Kwiatkowski-Phillips-Schmidt-Shin. (KPSS)

Luego, se estimarán las series temporales utilizando modelos SARIMA y VAR para encontrar el mejor ajuste "out-of-sample". Este proceso incluirá la división de los datos en conjuntos de entrenamiento y prueba, evaluando métricas de rendimiento como la media absoluta de los errores (MAE), la media cuadrática de los errores (MSE) y su raíz cuadrada (RMSE) para garantizar la precisión de pronóstico del modelo por medio del análisis de sus residuos.

Marco Teórico

MARCO TEÓRICO

En este trabajo hemos aplicado la metodología ARIMA y VAR para predecir la cantidad de consultas en una oficina pública de recaudación. De acuerdo con Peña (2005), el proceso ARIMA tiene tres componentes:

- El componente autorregresivo implica la regresión de la serie temporal contra sus propios valores pasados. La notación AR(p) indica la dependencia lineal de la observación actual a los p valores rezagados.

$$AR(p) = (1 - \phi_1 B - \cdots - \phi_p B^p) \tilde{z}_t = a_t$$

- El componente de media móvil modela la dependencia de la serie temporal respecto a los errores pasados. La notación MA(q) indica la dependencia de la observación actual de los q errores previos.

$$MA(q) = \tilde{z}_t = (1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_q B^q) a_t$$

- El componente integrado se refiere al grado de diferenciación necesaria para estabilizar la serie temporal, es decir, para convertirla en estacionaria. La notación I(d) indica el número de diferenciaciones necesarias.

$$ARMA(p, q) = (1 - \phi_1 B - \cdots - \phi_p B^p) \tilde{z}_t = (1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_q B^q) a_t$$

$$\begin{aligned} ARIMA(p, d, q) &= (1 - \phi_1 B - \cdots - \phi_p B^p)(1 - B^d) \tilde{z}_t \\ &= c + (1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_q B^q) a_t \end{aligned}$$

Por otra parte, el Vector Autorregresivo (VAR) consiste en extender la idea del modelo ARIMA al considerar simultáneamente múltiples series temporales estacionarias. Un sistema VAR de orden p incluye múltiples ecuaciones, cada una modelando una serie temporal diferente. La interdependencia entre las series se captura al incluir términos autorregresivos de cada serie en todas las ecuaciones del sistema donde la matriz de coeficientes autorregresivos representa las relaciones entre las series.

$$VAR(p) = Z_t - \mu = \Phi_1(Z_{t-1} - \mu) + \cdots + \Phi_p(Z_{t-p} - \mu) + a_t$$

Para identificar y poder aplicar estos modelos se deben seguir los siguientes pasos de acuerdo con Peña (2005):

1. Estacionariedad¹: Según Levendis (2018), se debe evaluar la estacionariedad de las series mediante gráficos de autocorrelación y autocorrelación parcial junto con pruebas estadísticas como los test de Dickey-Fuller Aumentado, Phillip Perron y KPSS.
 - El test de Dickey-Fuller y el test de Dickey-Fuller Aumentado (ADF) se centran en la hipótesis nula de que una serie temporal tiene una raíz unitaria y la hipótesis alternativa es que la serie es estacionaria después de diferenciarla. El ADF permite incluir términos de rezago adicionales en la regresión para mejorar la detección de la raíz unitaria.
 - El test de Phillips-Perron se centra en modelos de regresión no paramétricos, donde la hipótesis nula del test es que hay una raíz unitaria en la serie temporal, lo que indica no estacionariedad de la serie.
 - El test KPSS se utiliza para evaluar la hipótesis opuesta: la hipótesis nula permite un doble testeo, que la serie temporal sea estacionaria alrededor de una tendencia determinística o alrededor de una constante. En otras palabras, este test se enfoca en detectar si la serie tiene una tendencia estacionaria o no.
2. Determinación de los rezagos del ARIMA(p,d,q) y VAR(p): Se eligen los valores óptimos para p, d y q mediante métodos gráficos como la función de autocorrelación y autocorrelación parcial, así como criterios de información como el criterio basado en máxima verosimilitud de Akaike (AIC), de Schwarz (BIC) o de Hannan-Quinn (HQ).
3. Estimación: Se estiman los modelos ARIMA o VAR mediante el método de máxima verosimilitud.

Una vez estimados los modelos, Schmueli (2016) establece que se debe llevar a cabo la validación y el diagnóstico dividiendo los datos en entrenamiento y testeo, y aplicando métricas tales como MAE, MSE y RMSE a los residuos para evaluar la capacidad predictiva de los modelos. Además, se analizan de forma gráfica y se testean por correlación serial mediante la prueba de Ljung-Box o Breusch-Godfrey, por homocedasticidad mediante el test de Breush-Pagan y normalidad mediante el test de Jarque-Bera o el de Shapiro.

Según Greene (2018) se detalla un breve resumen de cada uno de ellos:

- **Test Ljung-Box de correlación serial.** Evalúa la presencia de autocorrelación en los residuos de un modelo. La hipótesis nula es que no hay autocorrelación significativa en los rezagos especificados. Si el valor p es menor que un umbral (por ejemplo, 0.05), se rechaza la hipótesis nula, indicando la presencia de autocorrelación en los residuos. Es comúnmente utilizado en análisis de series temporales para asegurar que no haya patrones residuales no capturados por el modelo.
- **Test de Breusch-Godfrey.** Se utiliza para evaluar la autocorrelación en los residuos de un modelo de regresión. Similar al test de Ljung-Box, evalúa si hay autocorrelación significativa en los residuos a través de múltiples rezagos. La hipótesis nula es que no hay autocorrelación. Un valor p bajo lleva al rechazo de la hipótesis nula, indicando la presencia de autocorrelación en los residuos.
- **Test de Jarque-Bera de Normalidad.** Este test evalúa si los residuos de un modelo tienen una distribución normal. La hipótesis nula es que los datos siguen una distribución normal. Si el valor p es menor que el umbral (por ejemplo, 0.05), se rechaza la hipótesis nula,

¹ Se refiere a estacionariedad en el sentido débil que implica la estabilidad de la media, la varianza y la estructura de covarianzas a lo largo del tiempo (Peña 2005).

sugiriendo que los residuos no se distribuyen normalmente. En el contexto de series temporales, la normalidad de los residuos es importante para realizar inferencias estadísticas precisas y para garantizar que el modelo esté capturando adecuadamente la variabilidad en los datos.

- **Test de Breusch-Pagan.** Evalúa la presencia de variabilidad no constante (heterocedasticidad) en los errores de un modelo de regresión. En resumen, la prueba examina si la dispersión de los errores es constante en todos los niveles de la variable independiente. Si el valor p es menor que un umbral (por ejemplo, 0.05), se rechaza la hipótesis nula, indicando que la varianza de los errores no es constante. Es decir, que hay heterocedasticidad significativa en los errores del modelo (la varianza es constante).



Análisis de Resultados

ANÁLISIS DE LAS SERIES SELECCIONADAS

Con el propósito de realizar una primera evaluación de los datos, se llevó a cabo la representación gráfica de las series originales. En este análisis, se examinó cuidadosamente cada caso para determinar la necesidad de aplicar diferenciación y lograr así la estacionariedad de las series temporales. La estacionariedad en su sentido débil se considera fundamental en el análisis de series temporales.

A continuación, se presenta un análisis detallado de cada serie temporal, para ilustrar las tendencias identificadas:

WHATSAPP (WAPP)

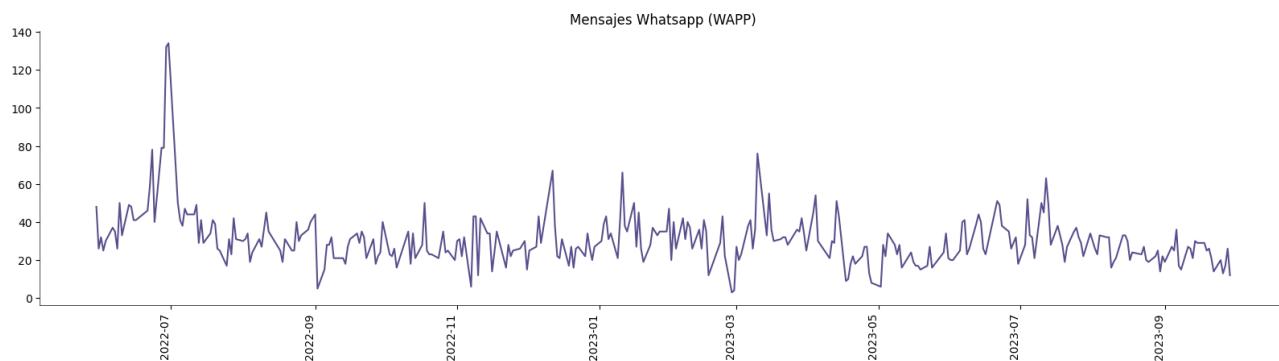


Fig. 3.1: Cantidad de mensajes de WhatsApp recibidos

La observación de la serie temporal correspondiente a los mensajes de WhatsApp (WAPP) revela la presencia de picos notables en determinadas fechas. Estos picos, potencialmente catalogados como valores atípicos u outliers, podrían estar vinculados a campañas publicitarias o promociones que incentivaron la utilización de este canal de comunicación. No obstante, a partir del mes de agosto de 2022, se evidencia una tendencia hacia la estabilización de la serie, indicando un comportamiento más estacionario. Este patrón sugiere que, a lo largo del tiempo, el empleo de WhatsApp como medio de comunicación ha experimentado una mayor previsibilidad y una disminución de la influencia de eventos excepcionales en su dinámica. Esto contribuye a comprender la evolución temporal del uso de WhatsApp, destacando la importancia de considerar factores estacionales y eventos promocionales al interpretar tendencias en series temporales.

TURNOS PRESENCIALES (TP)

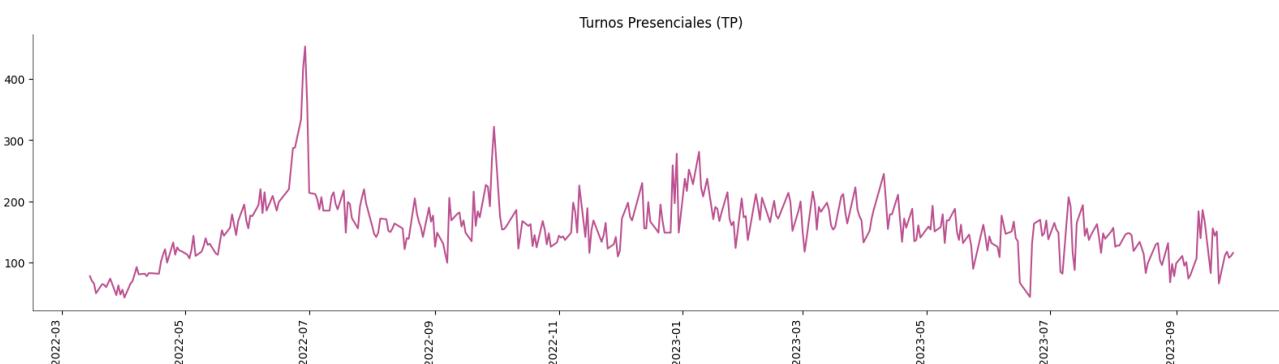


Fig. 3.2: Cantidad de personas atendidas de manera presencial

La inspección de la serie temporal asociada a la cantidad de turnos presenciales (TP) revela una tendencia positiva desde marzo de 2022 hasta julio de 2022. Adicionalmente, se evidencian picos en la cantidad de ciudadanos atendidos en fechas específicas, presumiblemente vinculados a la fecha de vencimiento de algún tributo o la culminación de una moratoria. Estos picos, como eventos extraordinarios, ejercen influencia sobre la serie temporal, generando indicios de no estacionariedad en la serie. En este análisis resalta la importancia de considerar factores estacionales y eventos excepcionales al interpretar patrones en series temporales, aportando una perspectiva significativa para comprender la dinámica de la atención presencial en la oficina de recaudación.

TRÁMITES A DISTANCIA (TAD)

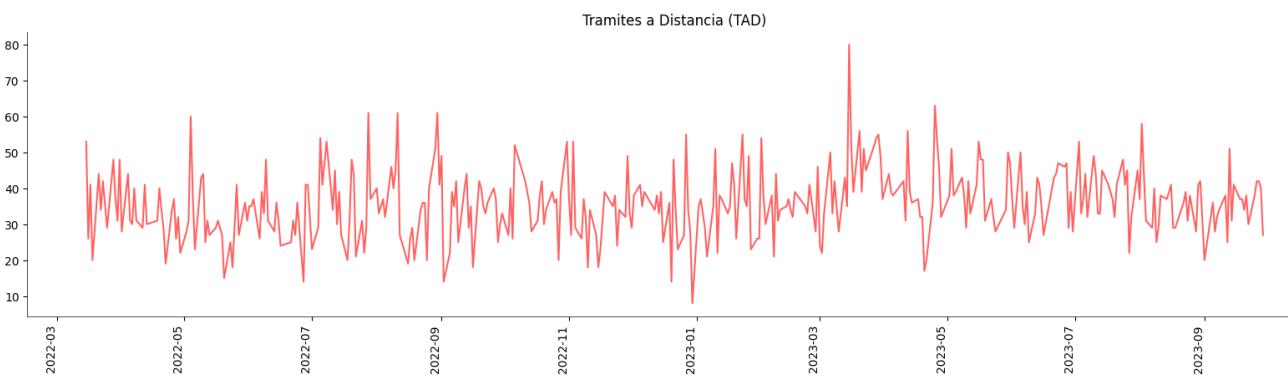


Fig. 3.3: Cantidad de trámites a distancia iniciados

Al abordar la serie temporal relacionada con la cantidad de trámites a distancia iniciados (TAD), se destaca la presencia de indicios de estacionariedad. La serie exhibe una media constante de aproximadamente treinta y seis trámites ingresados por día a lo largo de todo el período considerado. En consonancia con las otras series analizadas, no se evidencia la presencia de estacionalidad, lo que sugiere, de manera preliminar, la asunción de que la serie es estacionaria. Esto constituye un aspecto relevante en la comprensión de la dinámica de los trámites a distancia, subrayando la estabilidad en la frecuencia de iniciación de trámites a lo largo del tiempo y respaldando la aplicación de modelos de series temporales apropiados para su análisis posterior.

PLANES DE PAGO (PP)

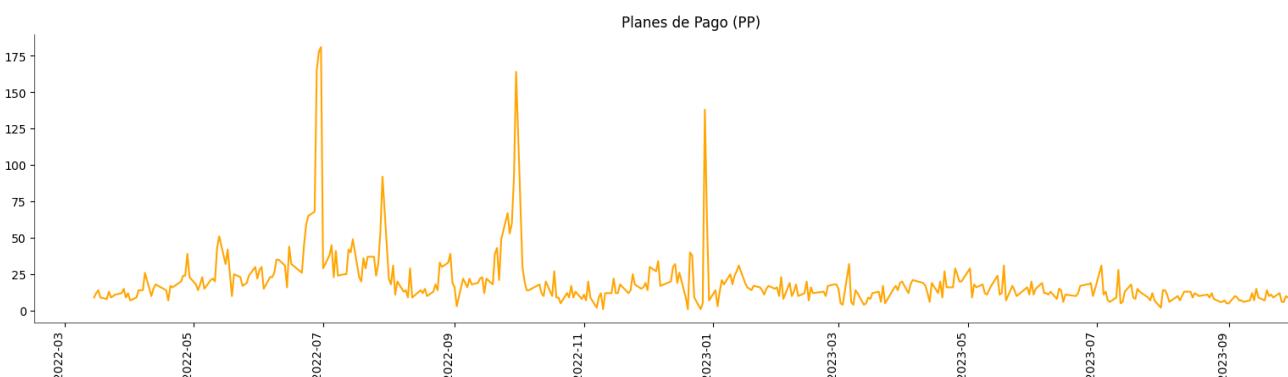


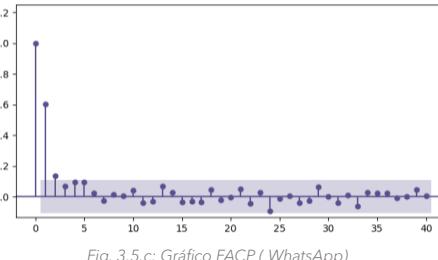
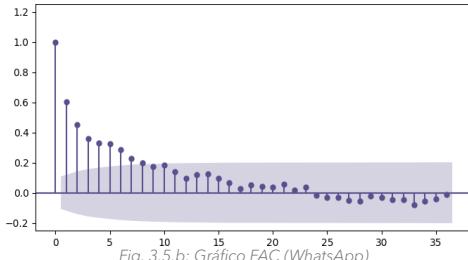
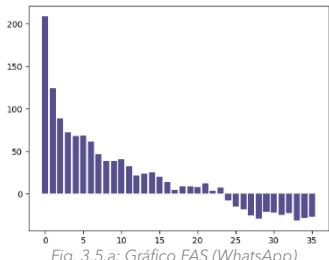
Fig. 3.4: Cantidad de planes de pago confeccionados

La exploración de la serie temporal relacionada con la cantidad de planes de pago confeccionados (PP) revela la presencia de tres picos notables, coincidentes con la fecha de vencimiento de una moratoria. Estos picos, identificados como eventos excepcionales, ejercen una influencia significativa en la dinámica de la serie. Además, se observa una marcada variabilidad entre los meses de mayo de 2022 y enero de 2023, sugiriendo que la serie podría no ser estacionaria durante este periodo.

A continuación, se procederá a graficar las Funciones de Autocorrelación Simple (FAS), las Funciones de Autocorrelación (FAC) y las Función de Autocorrelación Parcial (FACP) de las series, con el objeto de visualizar de una manera integral la estructura temporal de las series, identificar patrones estacionales, comprender relaciones temporales y determinar la estructura autorregresiva para la modelización y pronóstico preciso de las series temporales de acuerdo con el criterio recomendado por Peña (2005) que se detalla en el siguiente cuadro:

Modelos	FAC	FACP
AR(p)	Muchos coeficientes no nulos	Primeros p no nulos, resto cero
MA(q)	Primeros q no nulos, resto cero	Muchos coeficientes no nulos
ARMA(p,q)	Muchos coeficientes no nulos	Muchos coeficientes no nulos

WhatsApp (WAPP)



En el Análisis de la FAS para la serie temporal de Mensajes de WhatsApp (WAPP), se observa que la auto covarianza es alta para los lags cercanos a cero, lo que indica que la cantidad de mensajes de WhatsApp que llegan está altamente correlacionada en momentos cercanos en el tiempo. A medida que aumentan los lags, la auto covarianza disminuye, lo que indica que la cantidad de mensajes no está tan correlacionada en momentos más distantes en el tiempo.

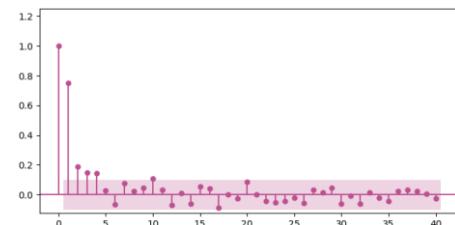
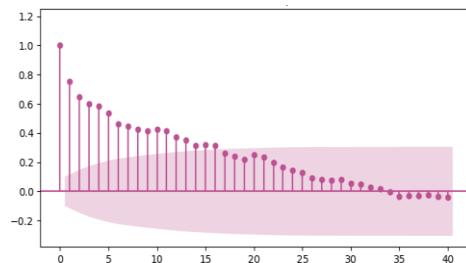
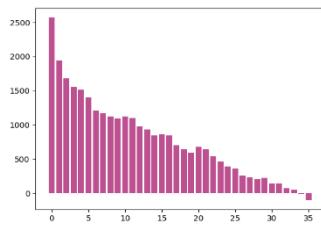
El Análisis de la FAC, revela una marcada autocorrelación positiva en los primeros seis lags, indicando dependencia significativa de los valores pasados. Este hallazgo sugiere la existencia de una relación fuerte y positiva entre los valores actuales y los valores precedentes en la serie compatible con un proceso AR.

Al examinar la FACP, se observa una fuerte correlación parcial en el primer lag, seguida de una rápida disminución en los lags subsiguientes. Esta característica sugiere que la correlación entre observaciones disminuye rápidamente a medida que se alejan en el tiempo, patrón que podría indicar un modelo AR(1). La fuerte correlación parcial en el primer lag sugiere influencia directa de la observación inmediatamente anterior en la serie temporal.

No se identifican patrones estacionales distintivos en la FAS ni en la FACP. Este resultado sugiere ausencia de ciclos temporales predecibles o patrones repetitivos en la serie, al menos en los lags considerados.

En relación con la estacionariedad, la serie no muestra indicios de ser estacionaria de acuerdo con la FAC.

TURNOS PRESENCIALES (TP)

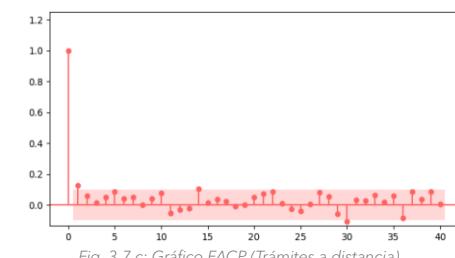
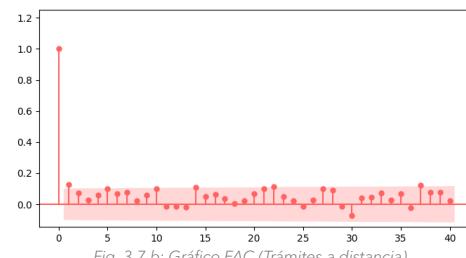
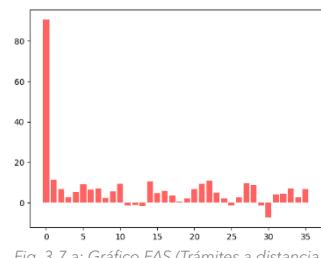


En este gráfico FAS correspondiente a la serie de Turnos Presenciales (TP), la auto covarianza es alta para los lags cercanos a cero, lo que indica que la cantidad de turnos presenciales está altamente correlacionada en momentos cercanos en el tiempo. A medida que aumentan los lags, la auto covarianza disminuye, lo que indica que la cantidad de turnos presenciales no está tan correlacionada en momentos más distantes en el tiempo.

Al examinar el gráfico de la FAC, se evidencia una disminución gradual y constante de los lags. Esta tendencia sugiere una correlación decreciente a medida que nos desplazamos en el tiempo, indicando que la serie sigue un proceso AR.

En cuanto al gráfico de la FACP, se destaca un valor significativo en el primer lag. Este resultado subraya una correlación parcial relevante en el rezago inicial con una fuerte influencia y en menor medida de los tres valores siguientes de la serie.

TRÁMITES A DISTANCIA (TAD)



La FAS correspondiente a la serie de Trámites a distancia (TAD), nos muestra que las barras disminuyen rápidamente en altura a medida que aumentan los lags. Esto sugiere que la cantidad de trámites solicitados no es constante en el tiempo, incluso podemos visualizar valores negativos.

Analizando el grafico de la FAC, observamos que presenta estacionariedad, ya que la rápida disminución de los valores de los lags indica la ausencia de una correlación significativa a medida que nos desplazamos en el tiempo.

En el gráfico de la FACP, se destaca la ausencia de lags que sobrepasen las bandas de confianza, sugiriendo la inexistencia de correlaciones parciales significativas en ningún punto de la serie temporal. Este hallazgo refuerza la noción de que los valores actuales no están fuertemente condicionados por observaciones en lags anteriores. Este análisis contribuye a consolidar la percepción de estacionariedad en la serie de Trámites a Distancia (TAD).

PLANES DE PAGO (PP)

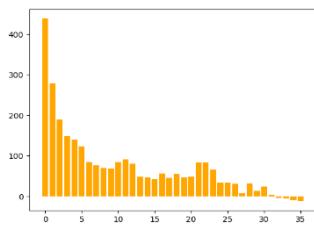


Fig. 3.8.a: Gráfico FAS (Planes de Pago)

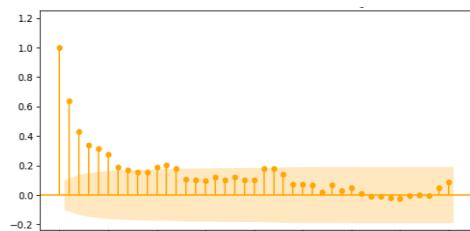


Fig. 3.8.b: Gráfico FAC (Planes de Pago)

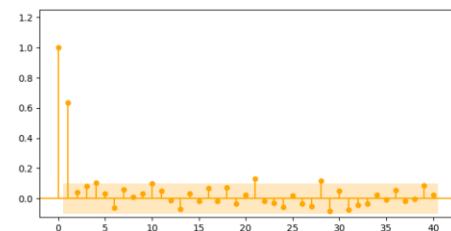


Fig. 3.8.c: Gráfico FACP (Planes de Pago)

La FAS de la serie de Planes de Pago (PP) muestra que la auto covarianza es alta para los lags cercanos a cero, lo que indica que la cantidad de planes de pago emitidos por la oficina gubernamental está altamente correlacionada en momentos cercanos en el tiempo. Es decir, a medida que pasa el tiempo se emiten menos cantidad de planes de pago.

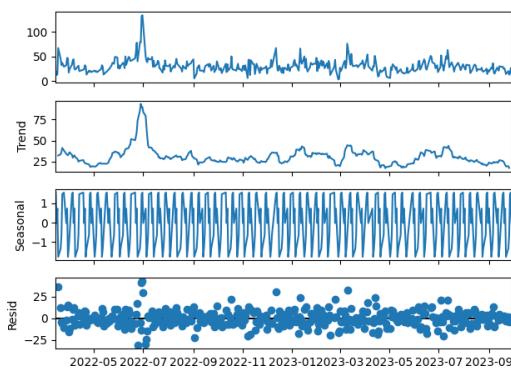
La FAC exhibe un comportamiento análogo a la serie de Mensajes de WhatsApp (WAPP). Se distingue una autocorrelación positiva significativa en los primeros seis lags, indicando una estructura AR.

En paralelo, al analizar la FACP, emerge una correlación parcial notable en el primer lag, seguida de una pronta disminución en lags consecutivos, sugiriendo la posibilidad de un modelo AR(1). Este patrón de correlaciones respalda la perspectiva de que la serie de Planes de Pago (PP) exhibe relativa estacionariedad, especialmente en sus lags más tardíos.

Con el fin de visualizar y analizar las componentes de la serie de tiempo, se realizó la descomposición aditiva, lo que puede ayudar a comprender la estructura de los datos y los patrones estacionales y de tendencia que pueden estar presentes.

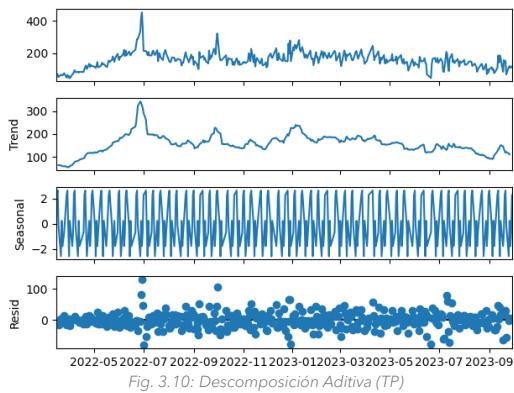
WHATSAPP (WAPP)

En el gráfico de la serie temporal original, la cantidad de mensajes recibidos de WhatsApp parece aumentar gradualmente con el tiempo. En el gráfico de la tendencia, se puede observar que la misma es positiva, lo que indica que la cantidad de mensajes recibidos de WhatsApp está aumentando con el tiempo. En el gráfico de la estacionalidad, se puede observar que la



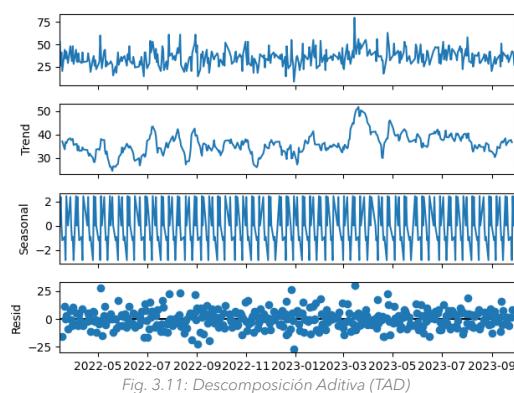
estacionalidad de la serie temporal es periódica, lo que indica que la cantidad de mensajes recibidos de WhatsApp varía en función del tiempo. En el gráfico de los residuos, se puede observar que estos parecen ser aleatorios, lo que indica que la variación aleatoria en los datos se ha eliminado correctamente.

TURNOS PRESENCIALES (TP)



En el gráfico de la serie temporal original, se puede observar que la cantidad de turnos presenciales solicitados parece aumentar gradualmente con el tiempo. En el gráfico de la tendencia, se puede observar que es positiva, lo que indica que la cantidad de turnos presenciales solicitados está aumentando con el tiempo. En el gráfico de la estacionalidad, se puede observar que un comportamiento periódico, lo que indica que la cantidad de turnos presenciales solicitados varía en función del tiempo. En el gráfico de los residuos, se puede observar que los residuos parecen ser aleatorios, lo que indica que la variación aleatoria en los datos se ha eliminado correctamente.

TRÁMITES A DISTANCIA (TAD)



En el gráfico de la serie temporal original, se puede observar que la cantidad de trámites a distancia realizados parece aumentar gradualmente con el tiempo. En el gráfico de la tendencia, se puede observar que es positiva, lo que indica que la cantidad de trámites a distancia realizados han aumentado con el tiempo. En el gráfico de la estacionalidad, se puede observar que es periódica, lo que indica que la cantidad de trámites a distancia realizados varía en función del tiempo. En el gráfico de los residuos, se puede observar que los residuos parecen ser aleatorios.

PLANES DE PAGO (PP)

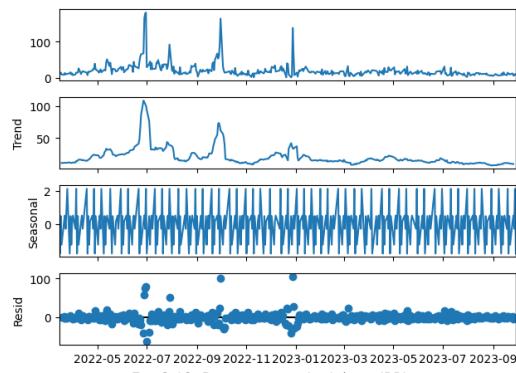


Fig. 3.12: Descomposición Aditiva (PP)

observar que los residuos parecen ser aleatorios.

En el gráfico de la serie temporal original, se puede observar que la cantidad de planes de pago efectuados parece aumentar gradualmente con el tiempo. En el gráfico de la tendencia, se puede observar que la misma es positiva, lo que indica que la cantidad de planes de pago efectuados está aumentando con el tiempo. En el gráfico de la estacionalidad, se puede observar que periodicidad, lo que indica que la cantidad de planes de pago efectuados varía en función del tiempo. En el gráfico de los residuos, se puede

Sobre el conjunto de datos, y con el objetivo de evaluar la estacionariedad de las series, se emplearon las pruebas de raíces unitarias mencionadas en la introducción:

- 1) Prueba de Dickey Fuller
- 2) Prueba de Dickey Fuller aumentada
- 3) Prueba KPSS
 - a. Los datos son estacionarios alrededor de una constante.
 - b. Los datos son estacionarios alrededor de una tendencia.
- 4) Prueba de Phillips-Perron
 - a. Incluye término independiente pero no incluye término lineal.
 - b. Incluya ambos términos.

El resultado obtenido en ellas se visualiza en la siguiente tabla:

Test	WAPP	TP	TAD	PP
Dickey Fuller	SI	SI	SI	SI
Dickey Fuller Aumentado	SI	SI	SI	SI
KPSS (a)	SI	SI	NO	NO
KPSS (b)	SI	NO	SI	SI
Phillips-Perron (a)	SI	SI	SI	SI
Phillips-Perron (b)	SI	SI	SI	SI

De acuerdo con los resultados solamente la serie WAPP es estacionaria de acuerdo con los tres test y sus variantes. Sin embargo, las FAC y FACP no muestran características estacionariedad para la misma. A su vez la serie TAD parece estacionaria de acuerdo con las FAC y FACP pero no lo es para el test KPSS(a) de estacionariedad alrededor de una constante. Es importante mencionar que, de acuerdo con Levendis (2018), la potencia de los test no es la misma, si bien el DF y el PP son bastante

utilizados suelen tener una tendencia al rechazo del H_0 mientras que el KPSS es más robusto y no es un test de raíz unitaria sino de estacionariedad. Por lo tanto, decidimos diferenciar todas las series ya que ninguna cumple con el método gráfico y los tests de forma conjunta.

A continuación, se presentan los gráficos de las series diferenciadas y se evalúo la estacionariedad por el test KPSS.

WhatsApp (WAPP)

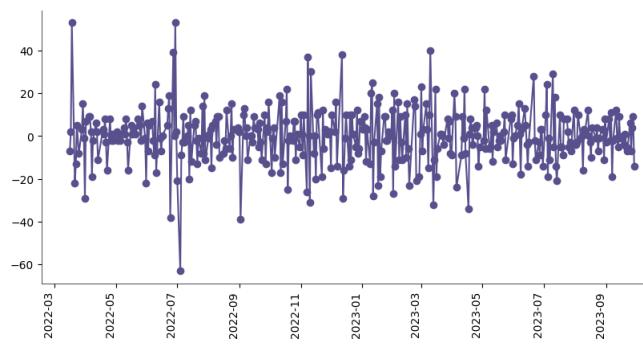


Fig. 3.13.a: Gráfico Diferencia entre valores consecutivos (WAPP)

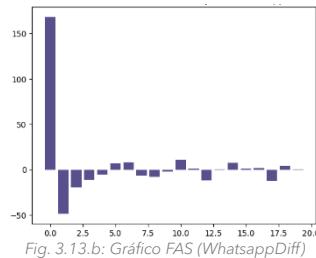


Fig. 3.13.b: Gráfico FAS (WhatsappDiff)

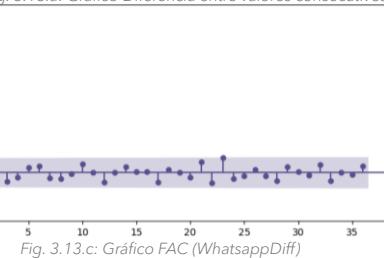


Fig. 3.13.c: Gráfico FAC (WhatsappDiff)

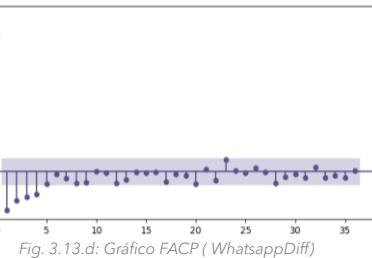


Fig. 3.13.d: Gráfico FACP (WhatsappDiff)

De acuerdo con el test esta serie es estacionaria alrededor de una constante y de una tendencia. Se procedió a realizar nuevamente el Gráfico FAC para verificar que luego de realizar la primera diferenciación, se cumpla con el requisito de estacionariedad.

TURNOS PRESENCIALES (TP)

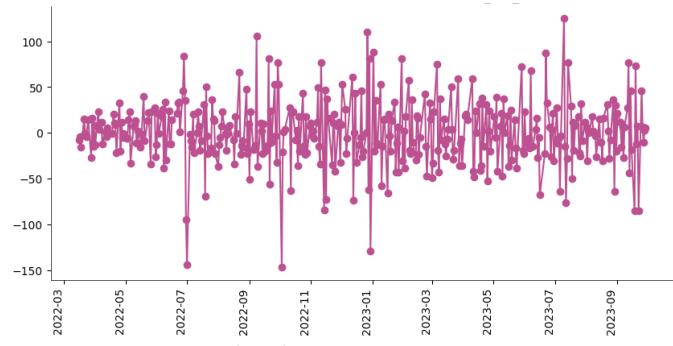


Fig. 3.14.a: Gráfico Diferencia entre valores consecutivos (TP)

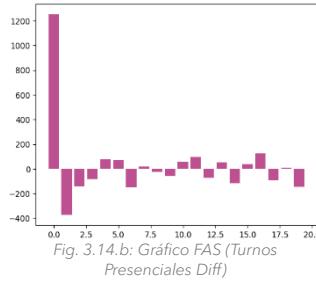


Fig. 3.14.b: Gráfico FAS (Turnos Presenciales Diff)

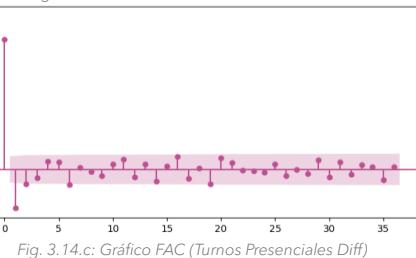


Fig. 3.14.c: Gráfico FAC (Turnos Presenciales Diff)

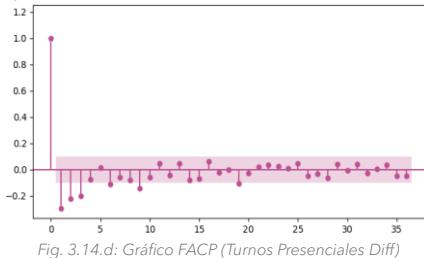


Fig. 3.14.d: Gráfico FACP (Turnos Presenciales Diff)

De acuerdo con el test esta serie es estacionaria alrededor de una constante y de una tendencia.

Se procedió a realizar nuevamente el Gráfico FAC para verificar que luego de realizar la primera diferenciación, se cumpla con el requisito de estacionariedad.

TRÁMITES A DISTANCIA (TAD)

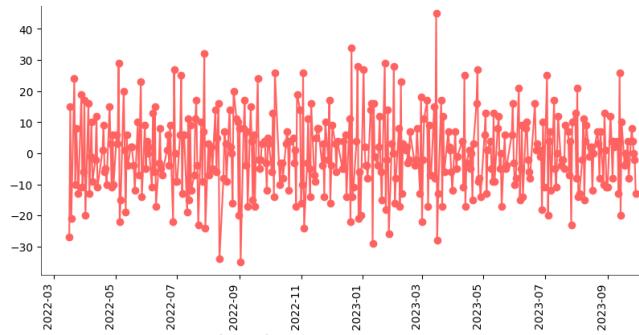


Fig. 3.15.a: Gráfico Diferencia entre valores consecutivos (TAD)

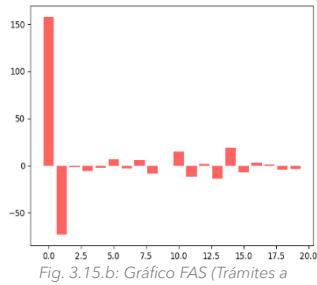


Fig. 3.15.b: Gráfico FAS (Trámites a distancia Diff)

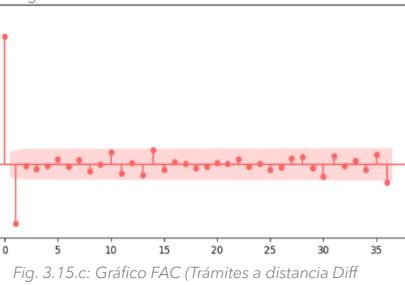


Fig. 3.15.c: Gráfico FAC (Trámites a distancia Diff)

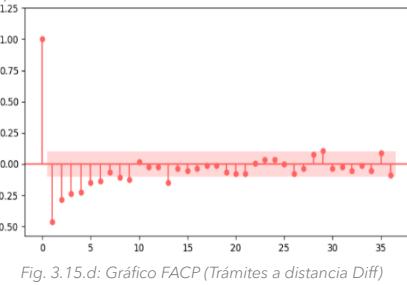


Fig. 3.15.d: Gráfico FACP (Trámites a distancia Diff)

De acuerdo con el test esta serie es estacionaria alrededor de una constante y cerca del límite no lo es respecto de una tendencia de manera que decidimos dejarla en primeras diferencias principalmente para poder interpretar los resultados de los parámetros obtenidos en el VAR al mantener todas las series con una diferenciación. Se procedió a realizar nuevamente el Gráfico FAC para verificar que luego de realizar la primera diferenciación, se cumpla con el requisito de estacionariedad.

PLANES DE PAGO (PP)

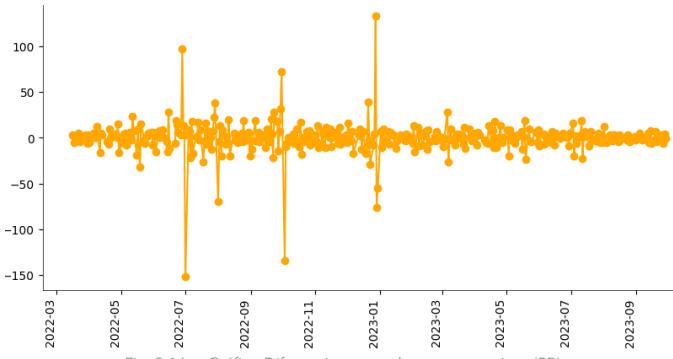


Fig. 3.16.a: Gráfico Diferencia entre valores consecutivos (PP)

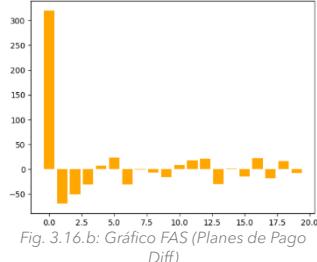


Fig. 3.16.b: Gráfico FAS (Planes de Pago Diff)

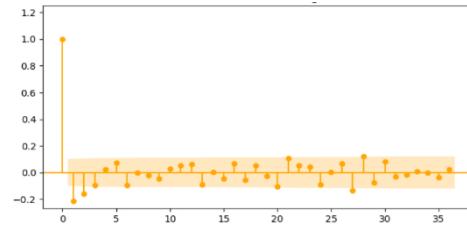


Fig. 3.16.c: Gráfico FAC (Planes de Pago Diff)

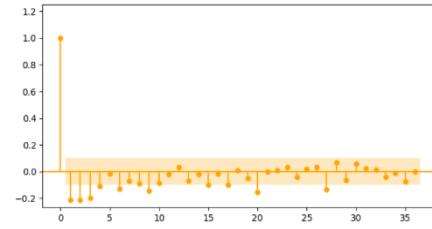


Fig. 3.16.d: Gráfico FACP (Planes de Pago Diff)

De acuerdo con el test esta serie es estacionaria alrededor de una constante y de una tendencia.

Se procedió a realizar nuevamente el Gráfico FAC para verificar que luego de realizar la primera diferenciación, se cumpla con el requisito de estacionariedad.

ESTIMACIÓN DE LAS SERIES SELECCIONADAS IDENTIFICACIÓN DEL MODELO ARIMA

En este parte identificaremos el orden del modelo ARIMA con el objeto de analizar y predecir patrones en series temporales. Éste, tal como se planteó en el marco teórico, combina componentes autorregresivos, de media móvil e integración para modelar la autocorrelación y la estacionariedad de los datos. Este enfoque permite capturar tendencias y patrones cíclicos en los datos a lo largo del tiempo.

WhatsApp (WAPP)

La salida del comando `auto_arima` respecto a la serie diferenciada de cantidad de mensajes recibidos de WhatsApp indica que, el modelo ARIMA seleccionado como el mejor es un ARIMA(1,0,1). La elección de este modelo se basa en la minimización del AIC, que es un criterio que penaliza modelos más complejos.

SARIMAX Results						
Dep. Variable:	y				No. Observations:	379
Model:	SARIMAX(1, 0, 1)				Log Likelihood	-1466.338
Date:	Sun, 12 Nov 2023				AIC	2938.676
Time:	14:55:10				BIC	2950.488
Sample:	0				HQIC	2943.364
					- 379	
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.4094	0.052	7.935	0.000	0.308	0.510
ma.L1	-0.8714	0.023	-38.094	0.000	-0.916	-0.827
sigma2	134.0392	5.538	24.205	0.000	123.185	144.893
Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB): 391.26				
Prob(Q):	0.96	Prob(JB): 0.00				
Heteroskedasticity (H):	0.43	Skew: 0.92				
Prob(H) (two-sided):	0.00	Kurtosis: 7.63				

Fig. 3.17: Coeficientes estimados del modelo (WAPP)

Además, se proporcionan los coeficientes estimados del modelo:

Coeficiente AR (autorregresivo): ar.L1 = 0,4094

Coeficiente MA (media móvil): ma.L1 = -0,8714

Varianza residual (σ^2): 134,0392

TURNOS PRESENCIALES (TP)

La salida del `auto_arima` respecto a la serie diferenciada de cantidad de turnos presenciales solicitados indica un orden ARIMA(1,0,1).

SARIMAX Results						
Dep. Variable:	y				No. Observations:	379
Model:	SARIMAX(1, 0, 1)			Log Likelihood	-1851.171	
Date:	Sun, 12 Nov 2023			AIC	3708.342	
Time:	14:55:14			BIC	3720.154	
Sample:	0			HQIC	3713.030	
	- 379					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.3774	0.056	6.728	0.000	0.267	0.487
ma.L1	-0.8179	0.030	-27.593	0.000	-0.876	-0.760
sigma2	1021.9381	54.378	18.793	0.000	915.359	1128.517
Ljung-Box (L1) (Q):	0.01	Jarque-Bera (JB):	61.87			
Prob(Q):	0.92	Prob(JB):	0.00			
Heteroskedasticity (H):	0.95	Skew:	0.38			
Prob(H) (two-sided):	0.76	Kurtosis:	4.83			

Fig. 3.18: Coeficientes estimados del modelo (TP)

Coeficientes estimados del modelo:

Coeficiente AR (autorregresivo): ar.L1 = 0,3774

Coeficiente MA (media móvil): ma.L1 = -0,8179

Varianza residual (σ^2): 1021,381

TRÁMITES A DISTANCIA (TAD)

En este caso, la salida del auto_arima respecto a la serie diferenciada de cantidad de trámites a distancia solicitados indica como el mejor al ARIMA(0,0,1).

SARIMAX Results						
Dep. Variable:	y				No. Observations:	379
Model:	SARIMAX(0, 0, 1)			Log Likelihood	-1388.714	
Date:	Sun, 12 Nov 2023			AIC	2781.427	
Time:	14:55:16			BIC	2789.302	
Sample:	0			HQIC	2784.552	
	- 379					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ma.L1	-0.9559	0.016	-59.466	0.000	-0.987	-0.924
sigma2	88.5845	5.034	17.599	0.000	78.719	98.450
Ljung-Box (L1) (Q):	2.02	Jarque-Bera (JB):	41.93			
Prob(Q):	0.16	Prob(JB):	0.00			
Heteroskedasticity (H):	0.68	Skew:	0.50			
Prob(H) (two-sided):	0.03	Kurtosis:	4.29			

Fig. 3.19: Coeficientes estimados del modelo (TAD)

Coeficientes estimados del modelo:

Coeficiente MA (media móvil): ma.L1 = -0,9559

Varianza residual (σ^2): 88,5845

PLANES DE PAGO (PP)

En este caso, la salida del auto_arima respecto a la serie diferenciada de cantidad de planes de pago realizados indica que el modelo ARIMA(1,0,1) es el más adecuado.

SARIMAX Results						
Dep. Variable:	y	No. Observations:	379			
Model:	SARIMAX(1, 0, 1)	Log Likelihood	-1591.707			
Date:	Sun, 12 Nov 2023	AIC	3189.414			
Time:	14:55:22	BIC	3201.227			
Sample:	0	HQIC	3194.102			
	- 379					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.5687	0.031	18.364	0.000	0.508	0.629
ma.L1	-0.9659	0.016	-59.907	0.000	-0.998	-0.934
sigma2	259.2176	5.251	49.365	0.000	248.926	269.509
Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB):	9745.29			
Prob(Q):	0.96	Prob(JB):	0.00			
Heteroskedasticity (H):	0.09	Skew:	2.24			
Prob(H) (two-sided):	0.00	Kurtosis:	27.43			

Fig. 3.20: Coeficientes estimados del modelo (PP)

Los coeficientes estimados del modelo son:

Coeficiente AR (autorregresivo): ar.L1 = 0,5687

Coeficiente MA (media móvil): ma.L1 = -0,9659

Varianza residual (σ^2): 259,2176

EVALUACIÓN DE LAS SERIES SELECCIONADAS

Para evaluar la idoneidad de ajuste de los modelos empleados en este estudio de series de tiempo, se entrenó cada serie temporal con un enfoque de separación de datos que asigna el 75% del conjunto total para el entrenamiento y reserva el 25% restante para el conjunto de prueba. Esta metodología de partición permite simular la capacidad de generalización de los modelos, proporcionando una evaluación más precisa de su rendimiento en datos no vistos.

Para la selección del modelo óptimo en cada serie temporal, se implementó la función `auto_arima`, que permite explorar de manera sistemática diversas combinaciones de hiperparámetros en busca de la configuración que minimiza el criterio de información de Akaike (AIC). El AIC es una medida que evalúa la calidad relativa de un modelo estadístico, penalizando la complejidad del modelo para evitar el sobreajuste. La búsqueda automática de hiperparámetros mediante la función `auto_arima` se basa en encontrar la combinación que minimiza el AIC, indicando así la configuración más apropiada para cada serie temporal.

Una vez identificados los hiperparámetros óptimos, se procedió a entrenar un modelo SARIMAX, que representa un modelo autorregresivo integrado de media móvil con términos estacionales. Este modelo, que combina componentes autorregresivos (AR), de media móvil (MA) e integrados (I), junto con términos estacionales (S), permite capturar patrones complejos en los datos temporales. Los resultados del modelo SARIMAX fueron visualizados mediante gráficos que representan la serie temporal original del conjunto de prueba, los valores medios de las predicciones y sus intervalos de confianza correspondientes. La inclusión de intervalos de confianza en los gráficos agrega una dimensión adicional al análisis, ofreciendo información sobre la incertidumbre asociada con las predicciones del modelo.

Las métricas seleccionadas para la evaluación de los modelos incluyen el Mean Square Error (MSE), el Mean Average Error (MAE) y el Root Mean Square Error (RMSE). Estas métricas proporcionan una evaluación comprehensiva del rendimiento de los modelos de series temporales, permitiendo comparaciones significativas entre diferentes enfoques de modelado y ayudando a identificar el modelo que mejor se ajusta a los datos observados.

WHATSAPP (WAPP)

La distribución de entrenamiento y testeo para la serie de WhatsApp (WAPP) es la siguiente:

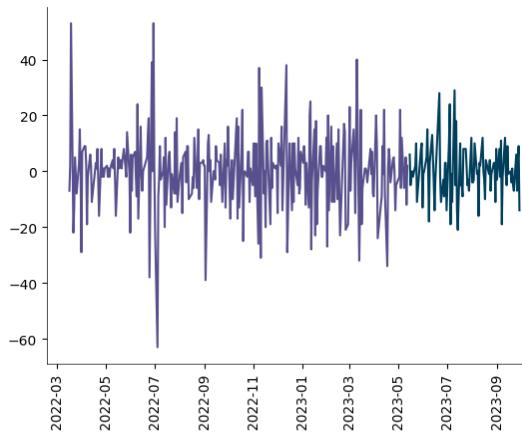


Fig. 3.21: Distribución Test/Testing serie WAPP

El resultado de la función `auto_arima` arrojo que el mejor modelo con el menor AIC (~2244) corresponde a un **ARIMA (2,0,2)**, que siguiendo la notación (p, d, q)

$p = 2$. Se usaron dos términos autoregresivos

$d = 0$. No se aplicó ninguna diferenciación para que la serie sea estacionaria.

$q = 2$. Se usaron dos términos de media móvil.

Se procede a representar gráficamente la serie temporal original del conjunto de prueba, junto con las predicciones generadas por el modelo SARIMAX ajustado con los hiperparámetros óptimos y su respectivo intervalo de confianza.

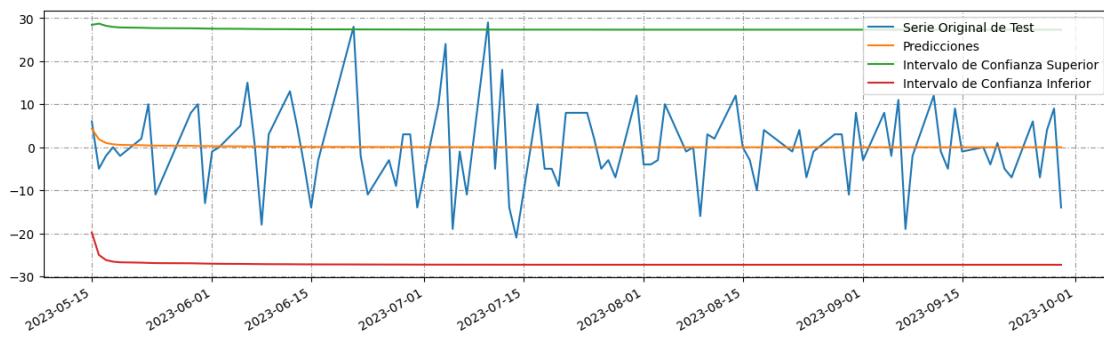


Fig. 3.22: Valores originales vs. Predicciones (WAPP)

Para finalizar, se realiza una evaluación detallada de las métricas asociadas al modelo resultante.

Métrica	Resultado
MSE	90.90
MAE	7.25
RMSE	9.53

TURNOS PRESENCIALES (TP)

La distribución de entrenamiento y testeo para la serie de Turnos Presenciales (TP) es la siguiente:

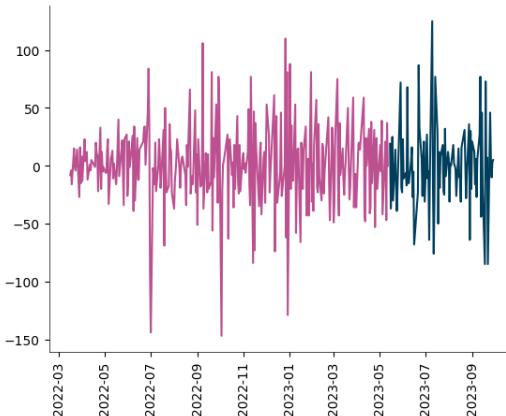


Fig. 3.23: Distribución Test/Testing serie TP

El resultado de la función `auto_arima` arrojo que el mejor modelo con el menor AIC (~2785) corresponde a un **ARIMA(1,0,1)**, que siguiendo la notación (p, d, q)

$p = 1$. Se usó un único término autoregresivo

$d = 0$. No se aplicó ninguna diferenciación para que la serie sea estacionaria.

$q = 1$. Se usó un único término de media móvil.

Se procede a representar gráficamente la serie temporal original del conjunto de prueba, junto con las predicciones generadas por el modelo SARIMAX ajustado con los hiperparámetros óptimos y su respectivo intervalo de confianza.

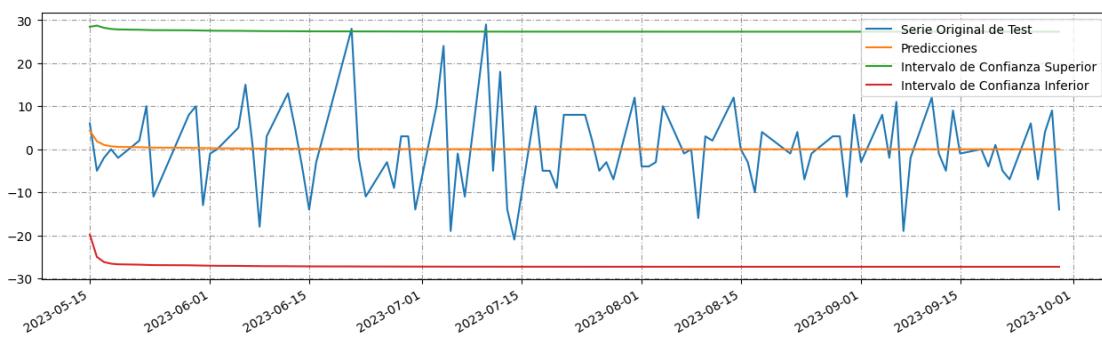


Fig. 3.24: Valores originales vs. Predicciones (TP)

Para finalizar, se realiza una evaluación detallada de las métricas asociadas al modelo resultante.

Métrica	Resultado
MSE	1280
MAE	26.36
RMSE	35.77

TRÁMITES A DISTANCIA (TAD)

La distribución de entrenamiento y testeо para la serie de Trámites a Distancia (TAD) es la siguiente:

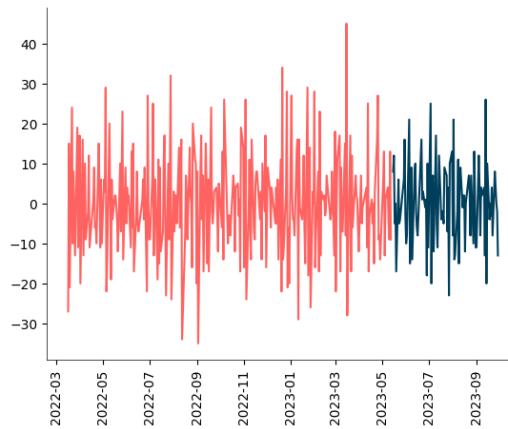


Fig. 3.25: Distribución Test/Testing serie TAD

El resultado de la función `auto_arima` arrojo que el mejor modelo con el menor AIC (~2117) corresponde a un **ARIMA (0,0,1)**, que siguiendo la notación (p, d, q)

$p = 0$. No se usó término autoregresivo

$d = 0$. No se aplicó ninguna diferenciación para que la serie sea estacionaria.

$q = 1$. Se usó un único término de media móvil.

Se procede a representar gráficamente la serie temporal original del conjunto de prueba, junto con las predicciones generadas por el modelo SARIMAX ajustado con los hiperparámetros óptimos y su respectivo intervalo de confianza.

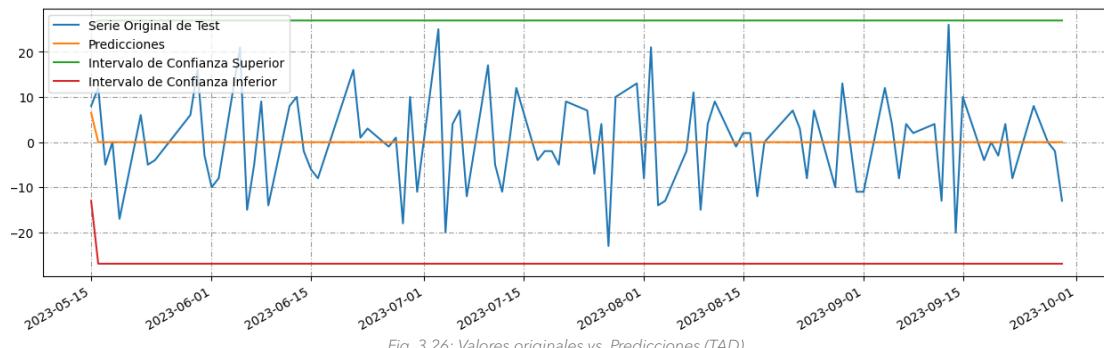


Fig. 3.26: Valores originales vs. Predicciones (TAD)

Para finalizar, se realiza una evaluación detallada de las métricas asociadas al modelo resultante.

Métrica	Resultado
MSE	105.49
MAE	8.26
RMSE	10.27

PLANES DE PAGO (PP)

La distribución de entrenamiento y testo para la serie de Planes de Pago (PP) es la siguiente:

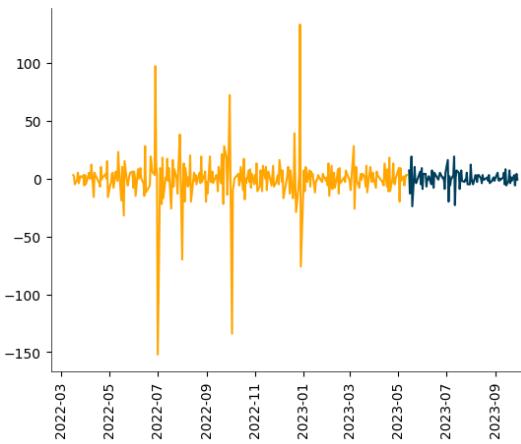


Fig. 3.27: Distribución Test/Testing serie PP

El resultado de la función `auto_arima` arrojo que el mejor modelo con el menor AIC (~2464) corresponde a un **ARIMA (1,0,1)**, que siguiendo la notación (p, d, q)

$p = 1$. Se usó un único término autoregresivo

$d = 0$. No se aplicó ninguna diferenciación para que la serie sea estacionaria.

$q = 1$. Se usó un único término de media móvil.

Se procede a representar gráficamente la serie temporal original del conjunto de prueba, junto con las predicciones generadas por el modelo SARIMAX ajustado con los hiperparámetros óptimos y su respectivo intervalo de confianza.

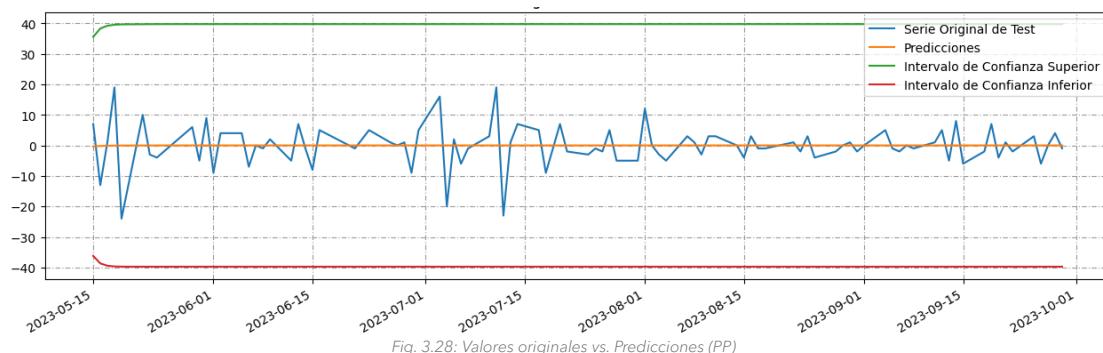


Fig. 3.28: Valores originales vs. Predicciones (PP)

Para finalizar, se realiza una evaluación detallada de las métricas asociadas al modelo resultante.

Métrica	Resultado
MSE	46.17
MAE	4.65
RMSE	6.79

COMPARACIÓN DE MODELOS:

Es fundamental destacar que la mera realización de cálculos métricos como el Error Cuadrático Medio (MSE), el Error Absoluto Medio (MAE) o la Raíz del Error Cuadrático Medio (RMSE) carece de significado intrínseco si no se emplean como herramientas de comparación. En otras palabras, el propósito central de este trabajo consiste en no solo calcular estas métricas, sino también en utilizarlas como instrumentos para evaluar y comparar el rendimiento de distintos modelos.

En este contexto, la interpretación de las métricas va más allá de un simple análisis numérico, se convierte en un medio para fundamentar decisiones informadas sobre la elección de modelos. Al comprender las implicaciones prácticas de estas métricas en el contexto del problema abordado, se logra una evaluación más completa y fundamentada. Por lo tanto, este enfoque holístico no solo arrojará luz sobre el rendimiento de los modelos, sino que también proporcionará una base sólida para la toma de decisiones en términos de selección y aplicación de modelos en futuros escenarios.

A continuación, se propone entonces comparar los resultados obtenidos en el inciso anterior. La metodología consistió en analizar dos modelos adicionales para cada una de las series. Se emplearon otros modelos Arima cercanos al del mejor orden seleccionado del resultado de la función auto_arima.

WHATSAPP (WAPP)

Dado a que se siguió la misma metodología para el primer y segundo caso se muestran directamente los resultados de las métricas para cada modelo. Los modelos ARIMA adicionales ajustados fueron:

1. **Modelo ARIMA (1,0,2)**
2. **Modelo ARIMA (2,0,1)**

Resumiendo los distintos métodos se confecciona un cuadro comparativo:

Métrica	ARIMA (2,0,2)	ARIMA (1,0,2)	ARIMA (2,0,1)
MSE	90.90	90.98	90.97
MAE	7.25	7.26	7.26
RMSE	9.53	9.53	9.53

Los resultados de estas métricas indican que los tres modelos tienen un rendimiento similar en términos de precisión predictiva. No hay diferencias sustanciales en términos de errores cuadráticos, errores absolutos o raíces cuadradas de errores cuadráticos.

TURNOS PRESENCIALES (TP)

Dado a que se siguió la misma metodología para el primer y segundo caso se muestran directamente los resultados de las métricas para cada modelo. Los modelos ARIMA adicionales ajustados fueron:

1. Modelo ARIMA (0,0,1)
2. Modelo ARIMA (1,0,0)

Resumiendo los distintos métodos se confecciona un cuadro comparativo:

Métrica	ARIMA (1,0,1)	ARIMA (0,0,1)	ARIMA (1,0,0)
MSE	1280	1281.36	1279.50
MAE	26.36	26.39	26.34
RMSE	35.77	35.79	35.77

Los resultados de estas métricas indican que los tres modelos tienen un rendimiento similar en términos de precisión predictiva. No hay diferencias sustanciales en términos de errores cuadráticos, errores absolutos o raíces cuadradas de errores cuadráticos.

TRÁMITES A DISTANCIA (TAD)

Dado a que se siguió la misma metodología para el primer y segundo caso se muestran directamente los resultados de las métricas para cada modelo. Los modelos ARIMA adicionales ajustados fueron:

1. Modelo ARIMA (1,0,1)
2. Modelo ARIMA (1,0,0)

Finalmente, resumiendo los distintos métodos se confecciona un cuadro comparativo:

Métrica	ARIMA (0,0,1)	ARIMA (1,0,1)	ARIMA (1,0,0)
MSE	105.49	105.41	106.37
MAE	8.26	8.27	8.33
RMSE	10.27	10.26	10.31

Los resultados de estas métricas indican que los tres modelos tienen un rendimiento similar en términos de precisión predictiva. No hay diferencias sustanciales en términos de errores cuadráticos, errores absolutos o raíces cuadradas de errores cuadráticos.

PLANES DE PAGO (PP)

Dado a que se siguió la misma metodología para el primer y segundo caso se muestran directamente los resultados de las métricas para cada modelo. Los modelos ARIMA adicionales ajustados fueron:

1. Modelo ARIMA (0,0,1)
2. Modelo ARIMA (1,0,0)

Resumiendo los distintos métodos se confecciona un cuadro comparativo:

Métrica	ARIMA (1,0,1)	ARIMA (0,0,1)	ARIMA (1,0,0)
MSE	46.17	46.41	46.29
MAE	4.65	4.66	4.66
RMSE	6.79	6.81	6.8

Los resultados de estas métricas indican que los tres modelos tienen un rendimiento similar en términos de precisión predictiva. No hay diferencias sustanciales en términos de errores cuadráticos, errores absolutos o raíces cuadradas de errores cuadráticos.

Para finalizar, es menester recalcar que la determinación del mejor modelo para problemas de pronóstico no debe basarse exclusivamente en una métrica. Cada métrica ofrece perspectivas diferentes sobre el rendimiento del modelo, por lo que es recomendable evaluar múltiples métricas y considerarlas en conjunto. Además, factores como la complejidad del modelo, la interpretabilidad, la facilidad de implementación y los recursos computacionales necesarios también son relevantes. La interpretación precisa de las métricas puede variar según el contexto específico del problema, y los requisitos del usuario, tales como la importancia de la precisión a corto o largo plazo, juegan un papel esencial en la elección del modelo adecuado. En última instancia, el proceso de selección del mejor modelo es complejo y requiere una comprensión integral que abarque métricas, factores adicionales, contexto y requisitos específicos del usuario o negocio.

ANÁLISIS DE RESIDUOS:

El análisis diagnóstico en series temporales es otra tarea esencial y necesaria para evaluar la validez de las suposiciones subyacentes y garantizar la calidad del modelo. En la siguiente sección se procederá a analizar los residuos de cada modelo, gráfico de la función de autocorrelación (FAC), test de Ljung-Box de correlación serial, test de Breusch-Godfrey, test de Jarque-Bera de normalidad y test de Breusch-Pagan.

WHATSAPP (WAPP)

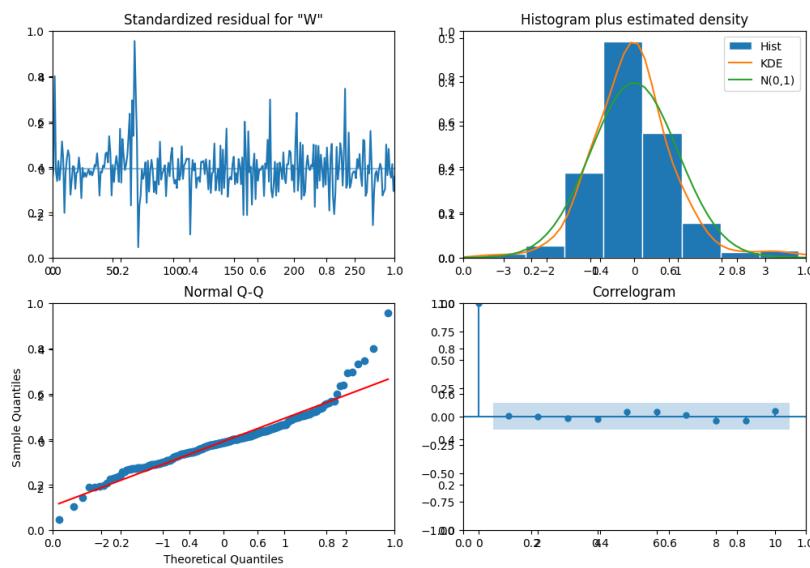


Fig. 3.29: Análisis residuos serie WhatsApp (WAPP) mejor modelo

Se resume en el siguiente cuadro, los resultados para cada uno de los test realizados sobre los residuos del modelo:

Test	P valor	Comentario
Breusch-Godfrey	0.9963	No se rechaza la H0
Ljung-Box	0.9694	No se rechaza la H0
Jarque-Bera	6.11e-75	Se rechaza la H0
Breusch-Pagan	0.3581	No se rechaza la H0

En resumen, los resultados indican que no hay autocorrelación significativa en los residuos, pero se rechaza la hipótesis de normalidad en la distribución de los mismos.

TURNOS PRESENCIALES (TP)

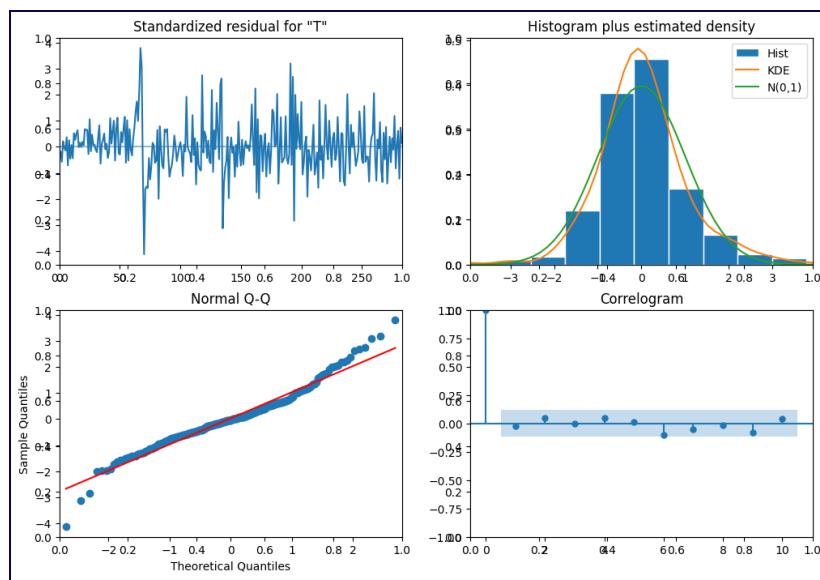


Fig. 3.30: Análisis residuos serie Turnos Presenciales (TP) mejor modelo ARIMA

Se resume en el siguiente cuadro, los resultados para cada uno de los test realizados sobre los residuos del modelo:

Test	P valor	Comentario
Breusch-Godfrey	0.8622	No se rechaza la H0
Ljung-Box	0.7082	No se rechaza la H0
Jarque-Bera	2.26e-12	Se rechaza la H0
Breusch-Pagan	0.6943	No se rechaza la H0

En resumen, los resultados indican que no hay autocorrelación significativa en los residuos, pero se rechaza la hipótesis de normalidad en la distribución de los mismos.

TRÁMITES A DISTANCIA (TAD)

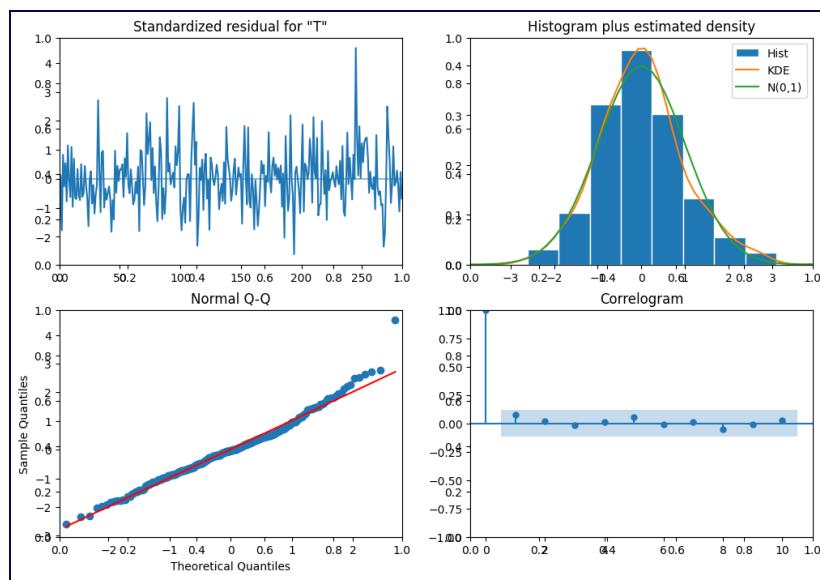


Fig. 3.31: Análisis residuos serie Trámites a Distancia (TAD) mejor modelo ARIMA

Se resume en el siguiente cuadro, los resultados para cada uno de los test realizados sobre los residuos del modelo:

Test	P valor	Comentario
Breusch-Godfrey	0.6034	No se rechaza la H0
Ljung-Box	0.2137	No se rechaza la H0
Jarque-Bera	4.57e-07	Se rechaza la H0
Breusch-Pagan	0.5494	No se rechaza la H0

En resumen, los resultados indican que no hay autocorrelación significativa en los residuos, pero se rechaza la hipótesis de normalidad en la distribución de los mismos.

PLANES DE PAGO (PP)

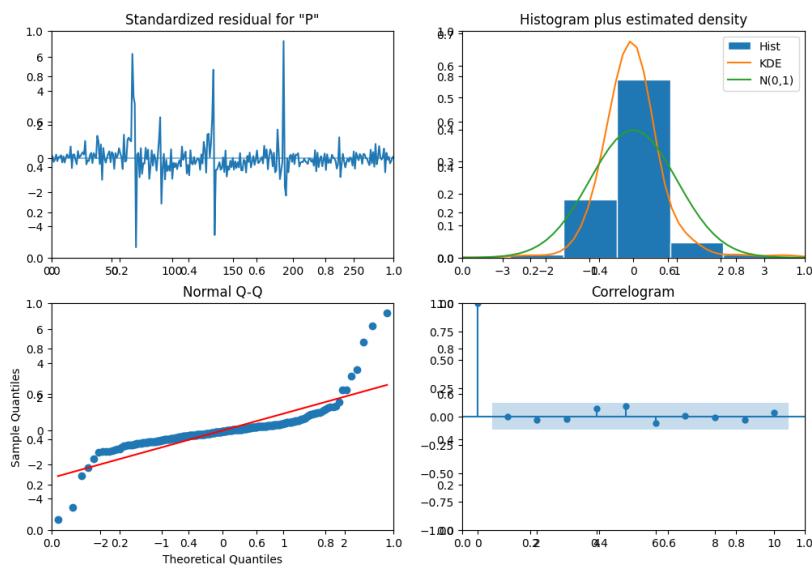


Fig. 3.32: Análisis residuos serie Planes de Pago (PP) mejor modelo ARIMA

Se resume en el siguiente cuadro, los resultados para cada uno de los test realizados sobre los residuos del modelo:

Test	P valor	Comentario
Breusch-Godfrey	0.9468	No se rechaza la H0
Ljung-Box	0.9976	No se rechaza la H0
Jarque-Bera	0.0	Se rechaza la H0
Breusch-Pagan	0.3691	No se rechaza la H0

En resumen, los resultados indican que no hay autocorrelación significativa en los residuos, pero se rechaza la hipótesis de normalidad en la distribución de los mismos.

Para concluir este apartado, recordar la importancia de considerar la no normalidad al interpretar los resultados y, si es posible, explorar técnicas o transformaciones adicionales para mejorar la normalidad de los residuos.

La función AUTOARIMA para train sugiere para realizar los pronósticos los modelos ARIMA(2,0,2) para WAPP, ARIMA(1,0,1) para TP, ARIMA(0,0,1) para TAD y ARIMA(1,0,1) para PP. La comparación con otras ARIMAs realizada anteriormente confirma los resultados obtenidos con la función AUTOARIMA para tres de las cuatro series. En la serie TP se obtienen mejores resultados aplicando un ARIMA(1,0,1).

El período a pronosticar fue de 15 días y los siguientes gráficos muestran una parte del sample de training, el testing y el forecasting. En WAPP y TAD el pronóstico muestra un valor estable. Mientras que en TP y PP el pronóstico es decreciente. Esto implica que se espera, para los próximos 15 días

hábiles, que se mantenga la cantidad de consultas vía WhatsApp y los Trámites a Distancia Iniciados y una menor cantidad de Trámites Presenciales y de Planes de Pagos Confeccionados.

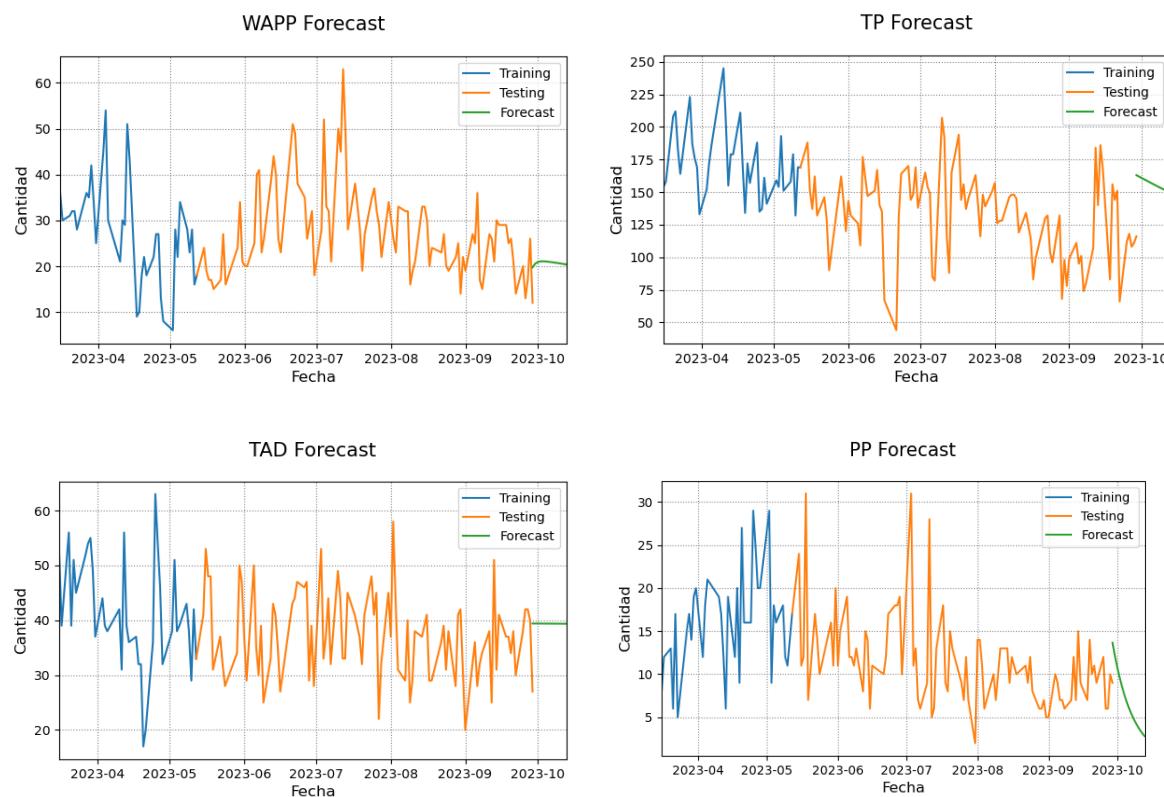


Fig. 3.33: Training, Testing y Forecast de las series

MODELO DE VECTORES AUTORREGRESIVOS:

El modelo VAR (Vector Autorregresivo) es una técnica analítica que examina las relaciones simultáneas entre variables mediante la construcción de ecuaciones simultáneas basadas en rezagos. Este enfoque es esencial para proyecciones conjuntas y revela las interacciones dinámicas entre diversas variables.

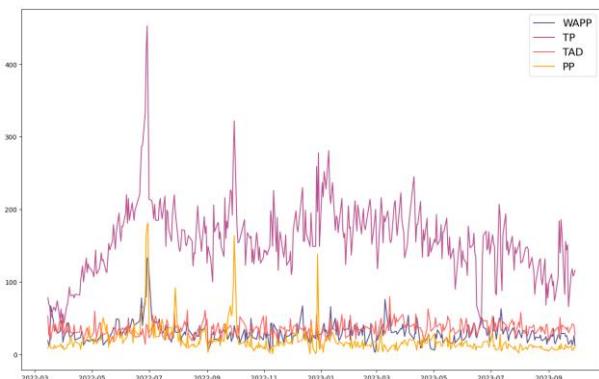


Fig. 3.34: Gráfico de series originales

Del gráfico, se deduce fácilmente que existe una relación entre la serie de Turnos Presenciales (TP) y la serie de Planes de Pago (PP). Esto se explica porque, aunque se pueden realizar planes de pago en línea, la mayoría de los planes se realizan presencialmente en la oficina.

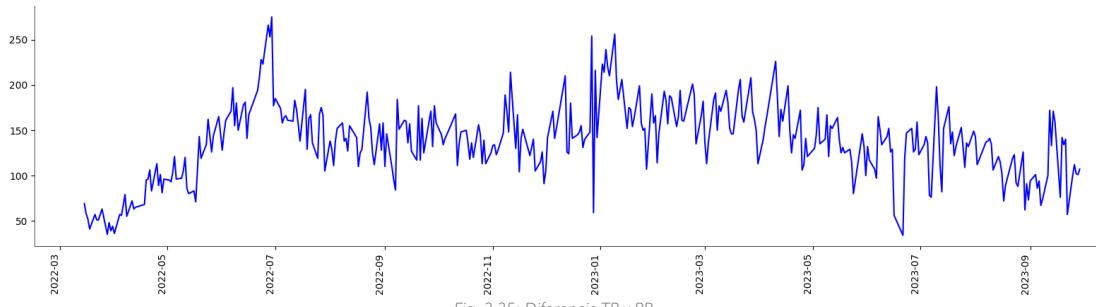


Fig. 3.35: Diferencia TP y PP

También se observa una relación entre los canales de atención, tanto presenciales como en línea. Los días con mayor cantidad de mensajes de WhatsApp coinciden con los días en que más ciudadanos se acercan a la oficina para realizar una consulta presencial.

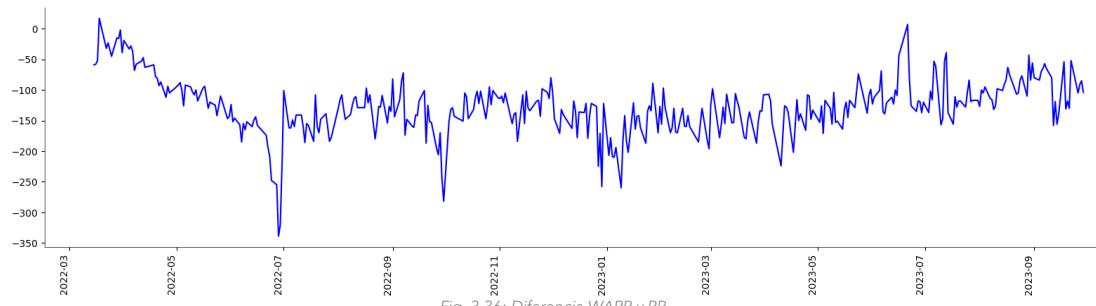


Fig. 3.36: Diferencia WAPP y PP

C.W Granger (1969) sugiere una noción de causalidad basada en la asimetría de los esquemas de correlación. La esencia de esta definición es que una variable x causa a otra variable y , si el conocimiento de los valores pasados de x permite un mejor pronóstico de y , que el obtenido con un conjunto de información determinado. Esta definición es susceptible de contrastación empírica y dado un par de variables aleatorias $[X, Y]$ siempre es posible evaluar cual antecede a la otra a partir de la observación de la matriz de correlaciones desfasadas correspondientes. (Balacco, 1986)

De esta forma, el Criterio de Granger es un concepto clave en el análisis de series temporales, utilizado para evaluar si una variable proporciona información útil en la predicción de otra. La hipótesis nula es que la serie temporal X no Granger-causa a la serie Y , lo que significa que los rezagos de X no aportan información significativa para predecir Y .

Los resultados del test de causalidad de Granger de las series analizadas son las siguientes:

	WAPP_x	TP_x	TAD_x	PP_x
WAPP_y	1.0000	0.0000	0.0087	0.0000
TP_y	0.1487	1.0000	0.2581	0.0009
TAD_y	0.1617	0.1941	1.0000	0.0006
PP_y	0.0588	0.0000	0.0355	1.0000

Los P-Value que arroja el Test de Granger para las siguientes relaciones:

1. WAPP (Mensajes por WhatsApp) → TP (Cantidad de Turnos Presenciales).
2. WAPP (Mensajes por WhatsApp) → PP (Cantidad de Planes de Pago).
3. TAD (Cantidad de Trámites a Distancia) → PP (Cantidad de Planes de Pago).
4. PP (Cantidad de Planes de Pago) → TAD (Cantidad de Trámites a Distancia).
5. PP (Cantidad de Planes de Pago) → TP (Cantidad de Turnos Presenciales):
6. TP (Cantidad de Turnos Presenciales) → PP (Cantidad de Planes de Pago).

Están por debajo del nivel de significación del 5%. Por lo tanto, hay evidencia suficiente para concluir, por ejemplo, que la cantidad de mensajes por WhatsApp Granger-causa la cantidad de turnos presenciales. Esto sugiere que la demanda de atención a través de mensajes de WhatsApp puede influir significativamente en la necesidad de turnos presenciales en la oficina.

En contraste, los P-Value de las siguientes relaciones:

1. TP (Cantidad de Turnos Presenciales) → WAPP (Mensajes por WhatsApp):
2. PP (Cantidad de Planes de Pago) → WAPP (Mensajes por WhatsApp):
3. WAPP (Mensajes por WhatsApp) → TAD (Cantidad de Trámites a Distancia):
4. TAD (Cantidad de Trámites a Distancia) → WAPP (Mensajes por WhatsApp):
5. TAD (Cantidad de Trámites a Distancia) → TP (Cantidad de Turnos Presenciales):
6. TP (Cantidad de Turnos Presenciales) → TAD (Cantidad de Trámites a Distancia):

Es superior al nivel de significación establecido del 5%. En consecuencia, no hay evidencia suficiente para rechazar la hipótesis nula, indicando que no existe una relación causal significativa en estas direcciones. Por ejemplo, no hay suficiente respaldo estadístico para afirmar que la cantidad de turnos presenciales Granger-causa la cantidad de mensajes por WhatsApp, a diferencia de la dirección opuesta.

La selección del orden del modelo VAR se basó en varios criterios de información, como el AIC, BIC, FPE y HQIC. Estos criterios evalúan el equilibrio entre el ajuste del modelo a los datos y su complejidad. Entre los diferentes órdenes considerados, el modelo VAR de orden 4 emerge como el más apropiado, ya que presenta valores bajos en el criterio AIC y FPE.

Luego de ajustar el modelo, se observan las siguientes correlaciones de los residuos:

	WAPP	TP	TAD	PP
WAPP	1,0000	0,2694	0,1479	0,1582
TP	0,2694	1,0000	0,1462	0,4940
TAD	0,1479	0,1462	1,0000	0,1310
PP	0,1582	0,4940	0,1310	1,0000

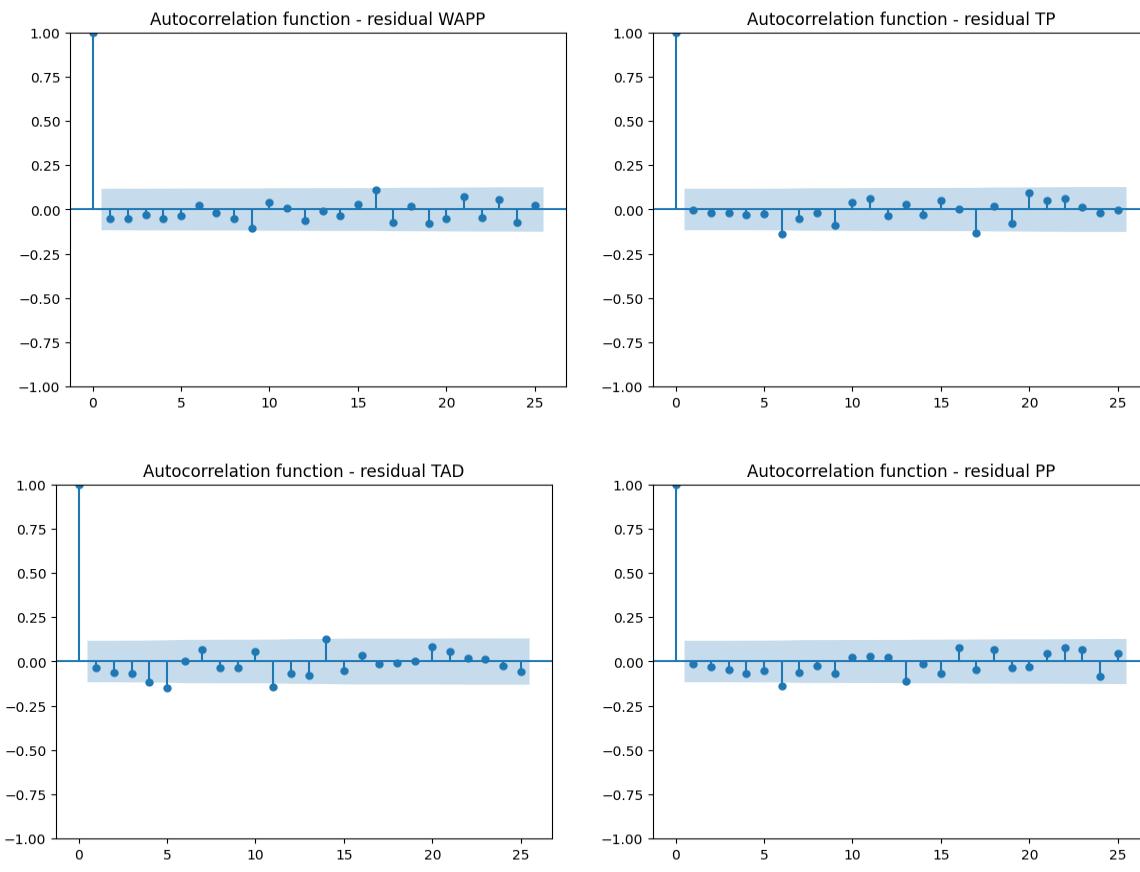


Fig. 3.37: Correlación de los residuos de las series

Los gráficos de los residuos muestran que no hay autocorrelaciones en cada residuo, lo que sugiere que los errores de predicción de una variable no están fuertemente relacionados con los de otras variables. Esto es positivo para un modelo VAR, ya que indica que los residuos no muestran patrones sistemáticos significativos.

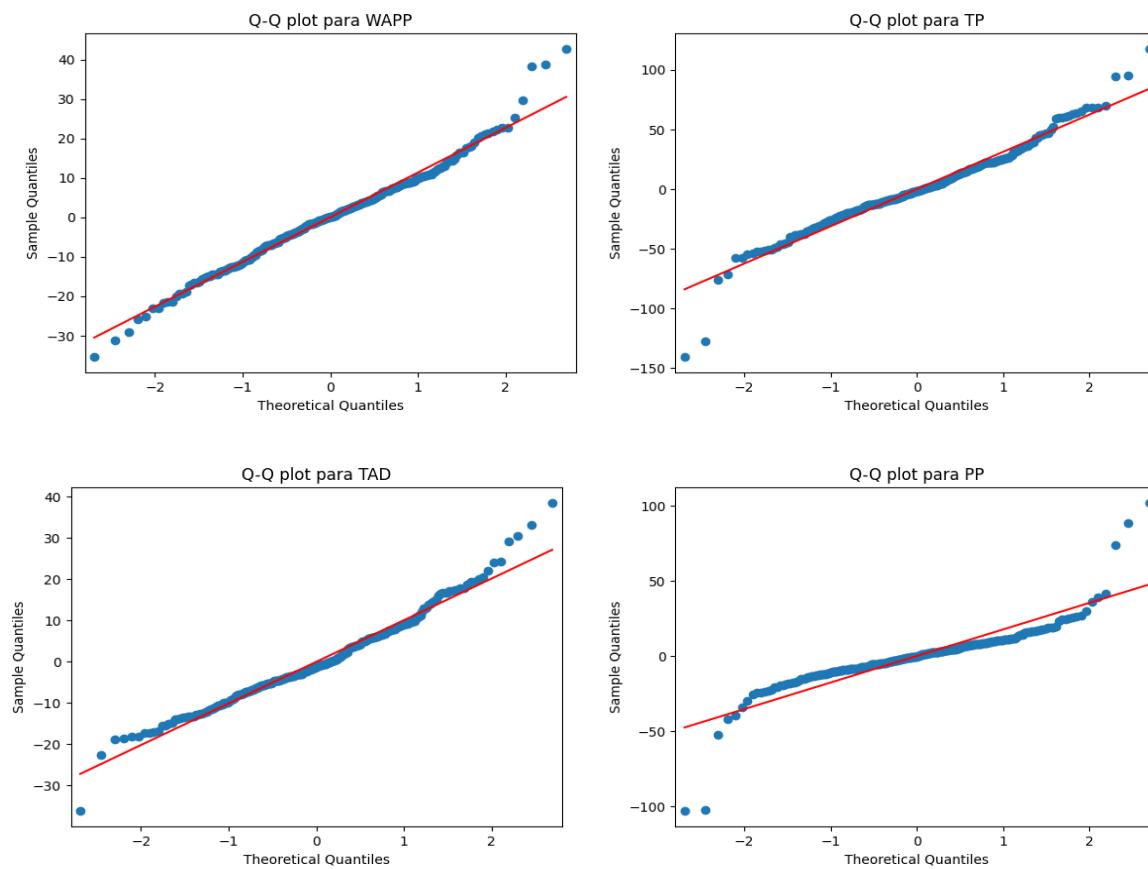


Fig. 3.38: Normalidad de los residuos de las series

Atento a que el p-value asociado con la prueba es significativamente menor que el umbral de significancia del 5%, se rechaza la hipótesis nula, que establece que los datos son generados por un proceso normalmente distribuido. Esto sugiere que los residuos no se distribuyen de manera normal, lo cual puede tener implicaciones en la validez de las inferencias realizadas a partir del modelo.

FORECASTING:

La evaluación del pronóstico de la media de la serie realizada con el modelo VAR, en testing (95 días), se muestra en los siguientes gráficos:

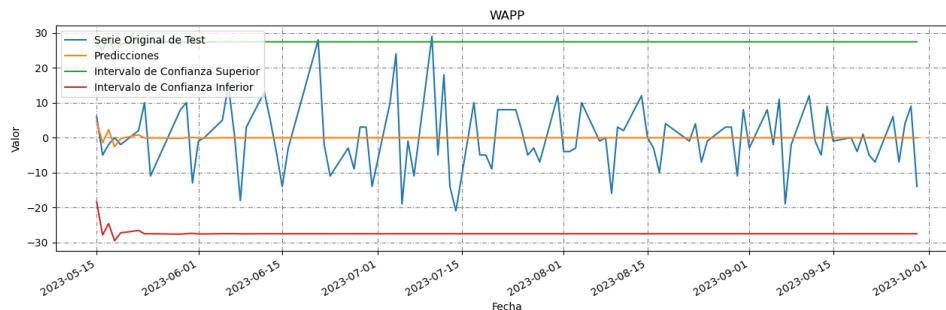


Fig. 3.39: Predicción serie de tiempo WAPP

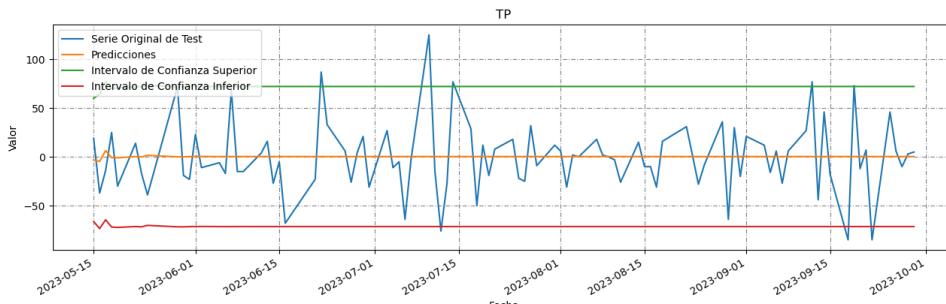


Fig. 3.40: Predicción serie de tiempo TP

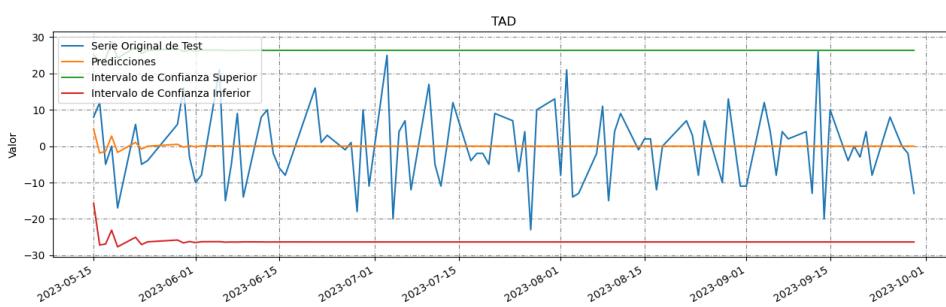


Fig. 3.41: Predicción serie de tiempo TAD

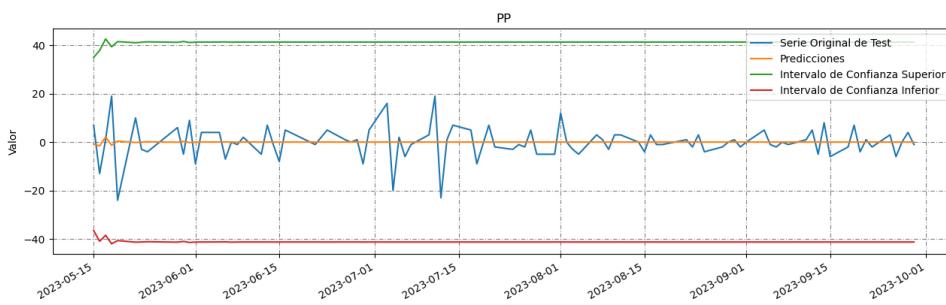


Fig. 3.42: Predicción serie de tiempo PP

Las métricas de evaluación de pronósticos mediante los residuos para los cuatro modelos AR del VAR se resumen en el cuadro siguiente:

Métrica	AR-WAPP	AR-TP	AR-TAD	AR-PP
MSE	90.7813	1281.1088	105.2459	46.7592
MAE	7.2389	26.4232	8.2807	4.6752
RMSE	9.5279	35.7926	10.2589	6.8381

Los resultados de los test de Jarque-Bera y Shapiro sobre los residuos de los modelos muestran que sólo para los modelos de WAPP y TAD los residuos presentan distribución normal ya que no se rechaza la H0 de los test.

P-Value	AR-WAPP	AR-TP	AR-TAD	AR-PP
JB	0.09	0.00	0.68	0.00
Shapiro	0.07	0.01	0.81	0.00

Los resultados obtenidos nos permiten seleccionar los mejores modelos ARIMA o VAR para cada variable.

Variable	Mejor Modelo	MSE	MAE	RMSE
WAPP	VAR(4)	90.7813	7.2389	9.5279
TP	ARIMA(1,0,1)	1280.0073	26.3683	35.7772
TAD	VAR(4)	105.2459	8.2807	10.2589
PP	ARIMA(1,0,1)	46.1791	4.6556	6.7955

Finalmente, se procedió a realizar el pronóstico y compararlo contra el dataset de Testing (25% de la base original).

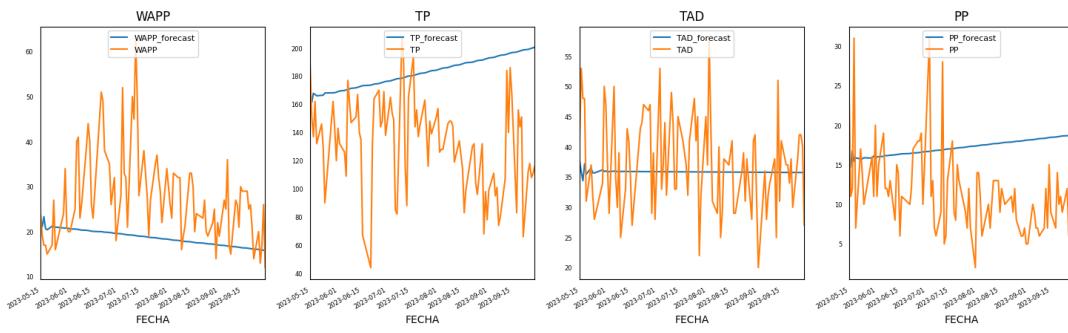


Fig. 3.43: Pronósticos de las series de tiempo

En el gráfico se observa que la variable TAD tiene un pronóstico más acertado. En cambio, se observa que tanto la variable TP como PP muestran una disminución en la precisión de las predicciones a medida que se proyecta hacia el futuro.

FUNCIÓN IMPULSO RESPUESTA:

El impulso respuesta es una herramienta útil para comprender cómo el cambio de una variable en el pasado afecta a otra variable en el presente. Para analizar esta dinámica, se aplica un impulso, que consiste en un cambio de unidad en una variable en un momento específico del pasado, y se observa cómo esta perturbación se propaga en otras variables a lo largo del tiempo. En general, los shocks duran aproximadamente 15 días.

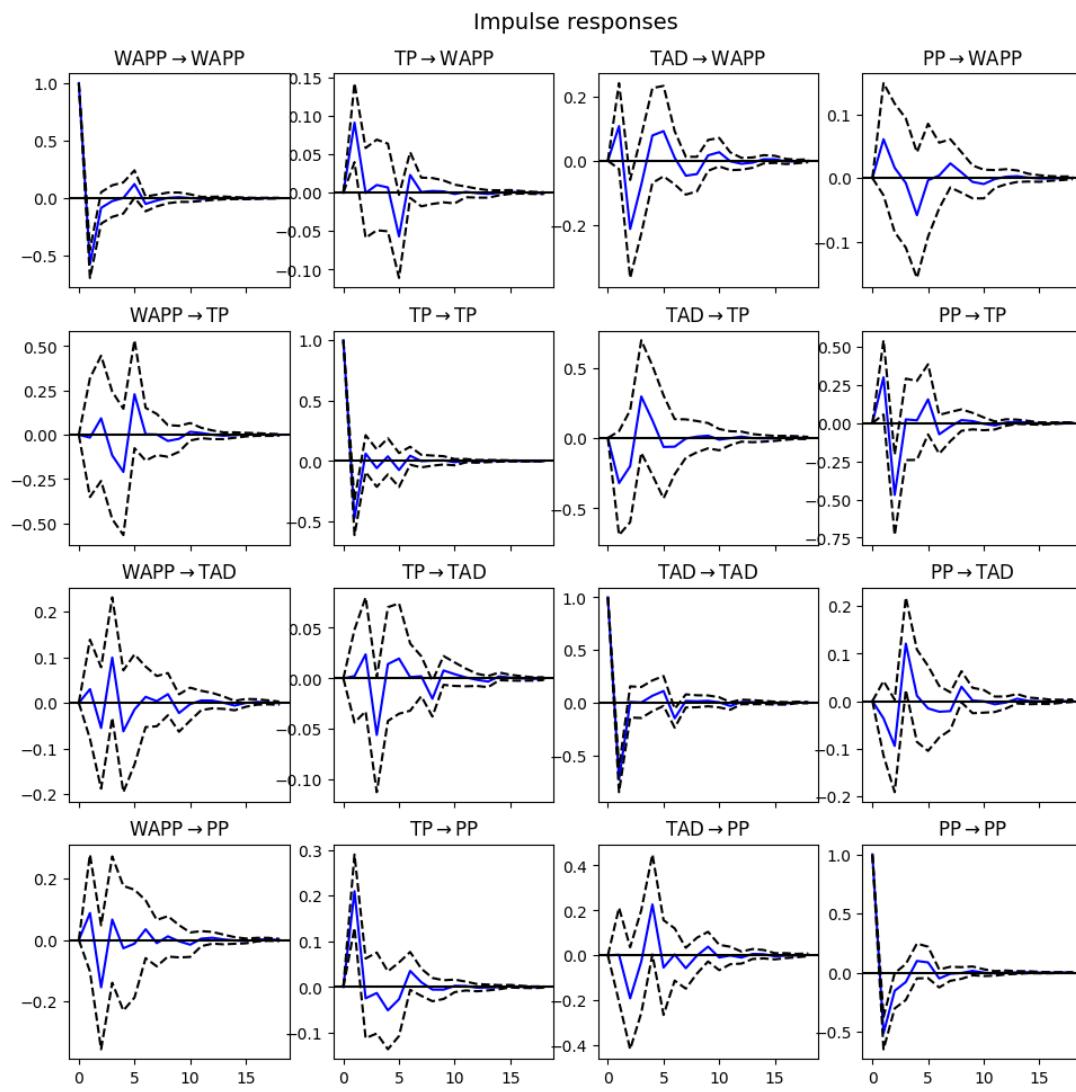


Fig. 3.44: Impulso respuestas de las series de tiempo

De esta forma, se puede observar que un choque positivo en la serie TP, tiene un efecto positivo en la salida de la variable PP y WAPP (es decir, más turnos presenciales, tiene un impacto positivo en la cantidad de planes de pago y mensajes de WhatsApp).

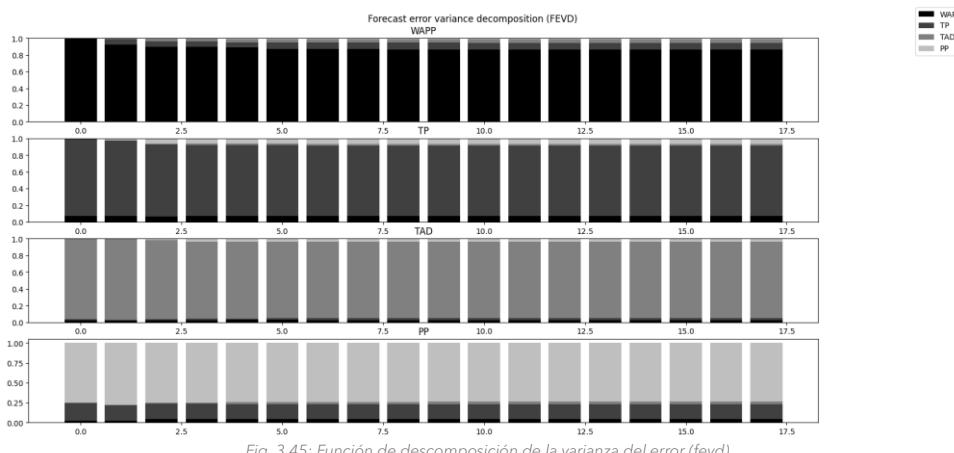


Fig. 3.45: Función de descomposición de la varianza del error (fevd)

1. WAPP:

En el primer período, la varianza de WAPP es completamente explicada por sí misma, ya que la entrada diagonal es 1 y las otras entradas son cero. A medida que avanzamos en el tiempo (a partir del segundo período), se observa que la contribución relativa de la varianza de WAPP disminuye gradualmente. No obstante, en el rezago n°18 la variable WAPP es explicada en un 86.6% por sí misma, un 7.96% por TP, un 4.37% por PP, y apenas un 1.04% por TAD.

2. TP:

En el primer período, la varianza de TP está principalmente explicada por sí misma (92.74%), mientras que las otras variables (WAPP, TAD, PP) contribuyen de manera insignificante. Esto disminuye gradualmente siendo que en el periodo 18 TP es explicada en un 84,04% por sí misma, un 7.8% por WAPP, un 6.36% por PP, y apenas un 2.02% por TAD.

3. TAD:

En el primer período, la varianza de TAD está principalmente explicada por sí misma (96.59%), mientras que las otras variables (WAPP, TP, PP) contribuyen de manera insignificante. La explicación de las otras variables en TAD es poco significativa incluyendo en el último período, siendo que TAD se explica a sí misma en un 91,27%.

4. PP:

En el primer período, la variable de PP está principalmente explicada por sí misma (75.20%), mientras que las otras variables (WAPP, TP, TAD) contribuyen de manera significativamente menor. Se destaca la importancia que tiene la variable TP, siendo que explica en un 21,97% a la variable PP. Incluyendo en el último periodo, PP se explica a sí misma en un 73.9% y TP la explica en un 19.13%.

Conclusiones

CONCLUSIONES

En la etapa inicial, se generaron gráficos para las series temporales de interés: la cantidad de mensajes de WhatsApp recibidos (WAPP), personas atendidas presencialmente (TP), trámites a distancia iniciados (TAD), y planes de pagos confeccionados (PP). Aunque todos los gráficos sugieren cierta estacionariedad, se observan picos en las series TP, PP y WAPP, relacionados con eventos promocionales o vencimientos de planes de pago.

La observación de la Función de Autocorrelación (FAC) revela que, salvo para la serie de TAD, los lags disminuyen lentamente, indicando una correlación persistente entre valores pasados y presentes, sugiriendo no estacionariedad.

Las pruebas de Raíces Unitarias indican que solo la serie WAPP es estacionaria según los tres tests realizados (Dickey Fuller, KPSS, Phillips Perron) y sus variantes. Por lo tanto, se procedió a diferenciar todas las series, adoptando un enfoque más cauteloso para abordar posibles complejidades y garantizar una preparación adecuada de las series para el análisis y modelización.

Se empleó el comando autoarima para detectar el mejor modelo, basándose en aquel que minimice el AIC. Este modelo se comparó con otros dos seleccionados según la observación de los gráficos FAC, FACP y los resultados del test autoarima, evaluando métricas como MSE, MAE y RMSE para determinar cuál es el mejor modelo.

Además, se procedió a realizar un análisis de diagnóstico de las series temporales sobre los residuos del modelo, evaluando la calidad del ajuste y la presencia de patrones no modelados.

Finalmente, se construyó un modelo de Vectores Autorregresivos (VAR) para realizar proyecciones conjuntas y revelar si existen interacciones entre las variables bajo estudio. El Test de Granger señala que varias variables presentan causalidad de Granger a otras. De la Función de Descomposición de la Varianza del Error, se deduce que el 20% de la cantidad de planes de pago se explica por la cantidad de turnos presenciales.

A continuación, se expone los mejores modelos para cada una de las series, conforme a las métricas del MSE, MAE y RMSE.

Variable	Mejor Modelo	MSE	MAE	RMSE
WAPP	VAR(4)	90.7813	7.2389	9.5279
TP	ARIMA(1,0,1)	1280.0073	26.3683	35.7772
TAD	VAR(4)	105.2459	8.2807	10.2589
PP	ARIMA(1,0,1)	46.1791	4.6556	6.7955

En conclusión, este exhaustivo análisis de las series temporales bajo estudio permite no solo identificar patrones estacionarios y eventos excepcionales, sino también modelar y prever su comportamiento futuro. La adopción de un enfoque cuidadoso, desde la diferenciación hasta la selección del mejor modelo, refleja el compromiso con la precisión y la robustez en el análisis de datos. La incorporación de pruebas estadísticas rigurosas, como el análisis de residuos, fortalece la validez de los resultados. El modelo VAR, al revelar relaciones causales entre variables, agrega una capa de comprensión a la complejidad del sistema estudiado. Este trabajo sienta las bases para tomar decisiones informadas y estratégicas, aprovechando las herramientas analíticas para interpretar y anticipar las tendencias en las series temporales analizadas.



Referencias bibliográficas

REFERENCIAS BIBLIOGRÁFICAS

- Balacco, H. (1986). Algunas consideraciones sobre la definición de causalidad de Granger en el análisis econométrico. *Económica*, 32.
- Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2008). Time series analysis: forecasting and control. John Wiley & Sons.
- Brockwell, P. J., & Davis, R. A. (Eds.). (2002). *Introduction to time series and forecasting*. New York, NY: Springer New York.
- Greene, W. H. (2008). The econometric approach to efficiency analysis. The measurement of productive efficiency and productivity growth, 1(1), 92-250.
- Gujarati, D. N. (2022). Basic econometrics. Prentice Hall.
- Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: principles and practice. OTexts.
- Levendis, J. D. (2018). *Time series econometrics*. Springer International Publishing.
- Peña, D. (2005). *Análisis de series temporales*. Alianza.
- Shmueli, G., & Lichtendahl Jr, K. C. (2016). *Practical time series forecasting with r: A hands-on guide*. Axelrod schnall publishers.
- Sims, C. A. (1980). Comparison of interwar and postwar business cycles: Monetarism reconsidered.
- Uriel, E. (1985). Análisis de Series Temporales–Modelos ARIMA, Edit. Paraninfo SA, España. Pág, 121-167.
- https://alkaline-ml.com/pmdarima/modules/generated/pmdarima.arima.auto_arima.html

Apéndices

APÉNDICES

Mean Square Error (MSE):

El MSE es una métrica que mide el promedio de los cuadrados de las diferencias entre las predicciones del modelo y los valores reales. Su fórmula se expresa como:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Mean Average Error (MAE):

El MAE representa el promedio de las diferencias absolutas entre las predicciones y los valores reales. Su fórmula se define como:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Root Mean Square Error (RMSE):

El RMSE es una métrica relacionada con el MSE pero se expresa en la misma escala que los valores originales. Se calcula tomando la raíz cuadrada del MSE:

$$RMSE = \sqrt{MSE}$$

Donde:

n : es el número total de observaciones

y_i : son los valores reales de la serie temporal

\hat{y}_i : son las predicciones del modelo



Repositorio del código

Haciendo clic en el siguiente logo, se podrá acceder al repositorio con los datasets utilizados y el código realizado.

